

Trabalho Modelos Mistos

Caio Gomes Alves e Daniel Krügel

25/11/2023

Peso de Capulho de Algodão

Continuando com a mesma base de dados de peso de capulhos de algodão (disponível em leg.ufpr.br/~walmes/data/) utilizada no trabalho de Regressão Não-Linear, foi observado que uma regressão linear polinomial (quadrática) dos valores de desfolhamento artificial (`desf`) se ajusta satisfatoriamente bem aos dados. Dessa forma, agora será ajustado um modelo linear misto para os mesmos dados, com efeito aleatório no intercepto de cada estágio de desenvolvimento (Vegetativo, Botão Floral, Florescimento, Maçã e Capulho).

```
# Dados
cap <- read.table("algodao.txt",
                  header = TRUE,
                  sep = "\t",
                  encoding = "latin1")

# Ajustando os valores de desfolhamento:
cap$desf <- cap$desf/100

# Selecionando as variáveis de interesse:
cap <- subset(cap, select = c(estag, desf, pcapu))

# Estágios de crescimento:
cap$estag <- factor(cap$estag, labels = c("Vegetativo",
                                          "Botão Floral",
                                          "Florescimento",
                                          "Maçã",
                                          "Capulho"))

# Ajuste do modelo:
(mod_alea <- lme(pcapu ~ desf + I(desf^2), data = cap,
                 random = ~1 | estag, method = "ML"))
```

```
## Linear mixed-effects model fit by maximum likelihood
##   Data: cap
##   Log-likelihood: -365.293
##   Fixed: pcapu ~ desf + I(desf^2)
## (Intercept)      desf    I(desf^2)
##   29.821813    1.122043   -12.274651
##
## Random effects:
## Formula: ~1 | estag
```

```
##          (Intercept) Residual
## StdDev:    3.318973  4.25322
##
## Number of Observations: 125
## Number of Groups: 5
```

```
# Sumário do ajuste:
summary(mod_alea)
```

```
## Linear mixed-effects model fit by maximum likelihood
##   Data: cap
##       AIC      BIC    logLik
##  740.586 754.7276 -365.293
##
## Random effects:
## Formula: ~1 | estag
##          (Intercept) Residual
## StdDev:    3.318973  4.25322
##
## Fixed effects:  pcapu ~ desf + I(desf^2)
##               Value Std.Error   DF   t-value p-value
## (Intercept)  29.821813  1.707030  118  17.470004  0.0000
## desf         1.122043  3.839667  118   0.292224  0.7706
## I(desf^2)    -12.274651  3.681959  118  -3.333729  0.0011
## Correlation:
##          (Intr) desf
## desf      -0.349
## I(desf^2)  0.270 -0.959
##
## Standardized Within-Group Residuals:
##      Min      Q1      Med      Q3      Max
## -2.5694792 -0.7584264  0.1873716  0.6596735  2.1516757
##
## Number of Observations: 125
## Number of Groups: 5
```

```
# Como a estimativa linear de desf não foi significativa,
# vamos ajustar um segundo modelo somente com o ajuste quadrático:
(mod_alea_2 <- lme(pcapu ~ I(desf^2), data = cap,
                  random = ~1 | estag, method = "ML"))
```

```
## Linear mixed-effects model fit by maximum likelihood
##   Data: cap
##   Log-likelihood: -365.3367
##   Fixed: pcapu ~ I(desf^2)
## (Intercept)  I(desf^2)
##   29.99592   -11.24289
##
## Random effects:
## Formula: ~1 | estag
##          (Intercept) Residual
## StdDev:    3.318894  4.25477
##
```

```
## Number of Observations: 125
## Number of Groups: 5
```

```
summary(mod_alea_2)
```

```
## Linear mixed-effects model fit by maximum likelihood
##   Data: cap
##       AIC      BIC    logLik
##  738.6735 749.9867 -365.3367
##
## Random effects:
## Formula: ~1 | estag
##      (Intercept) Residual
## StdDev:      3.318894  4.25477
##
## Fixed effects:  pcapu ~ I(desf^2)
##               Value Std.Error DF   t-value p-value
## (Intercept)  29.99592  1.593194 119  18.82754     0
## I(desf^2)   -11.24289  1.040528 119 -10.80498     0
## Correlation:
##      (Intr)
## I(desf^2) -0.245
##
## Standardized Within-Group Residuals:
##      Min      Q1      Med      Q3      Max
## -2.5882796 -0.7482807  0.1759246  0.6730137  2.1713702
##
## Number of Observations: 125
## Number of Groups: 5
```

```
# Comparação dos modelos:
anova(mod_alea_2, mod_alea)
```

```
##           Model df      AIC      BIC    logLik  Test   L.Ratio p-value
## mod_alea_2     1  4 738.6735 749.9867 -365.3367
## mod_alea       2  5 740.5860 754.7276 -365.2930 1 vs 2 0.08746296  0.7674
```

Como o valor da ANOVA comparativa dos modelos deu não significativa, manteremos somente o ajuste com o efeito quadrático (mod_alea_2). Com o modelo ajustado para os diferentes estágios, podemos extrair as estimativas dos efeitos aleatórios e verificar os diferentes valores ajustados:

```
# Estimativas dos efeitos aleatórios por estágio:
ranef(mod_alea_2)
```

```
##           (Intercept)
## Vegetativo      2.517614
## Botão Floral    1.590520
## Florescimento  -4.623720
## Maçã            -3.005500
## Capulho         3.521086
```

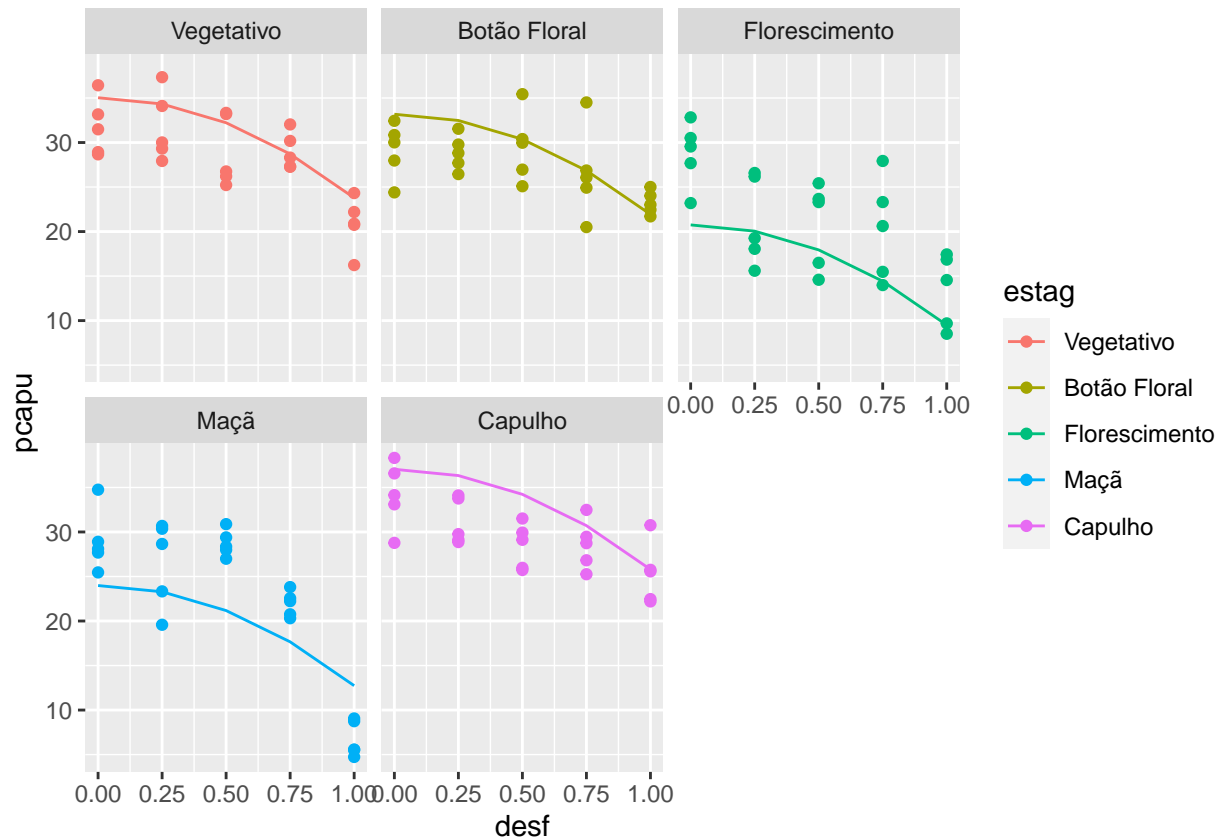
```
# Estimativa dos efeitos fixos:
fixef(mod_alea_2)
```

```
## (Intercept)    I(desf^2)
##      29.99592    -11.24289
```

```
# Base com os valores ajustados:
ajustados2 <- cap
```

```
ajustados2$ajust <- fitted(mod_alea_2) + rep(unlist(ranef(mod_alea_2)
                                                    , use.names = F), each = 25)
```

```
# Gráfico dos ajustes:
ggplot(ajustados2, aes(x = desf, y = pcapu, group = estag, color = estag)) +
  geom_point() +
  geom_line(aes(y = ajust)) +
  facet_wrap(~estag)
```



Podemos perceber que o modelo linear polinomial quadrático se ajusta melhor a alguns estágios de desenvolvimento do que os outros. A partir disso, é possível analisar agora as medidas de qualidade de ajuste.

```
# Covariância da estimativa dos efeitos fixos:
vcov(mod_alea_2)
```

```
##           (Intercept) I(desf^2)
## (Intercept)    2.497654 -0.399516
## I(desf^2)      -0.399516  1.065376
```

```
# Componentes de variância d
VarCorr(mod_alea_2)
```

```
## estag = pdLogChol(1)
##           Variance StdDev
## (Intercept) 11.01505 3.318894
## Residual    18.10307 4.254770
```