

# CE225 - Modelos Lineares Generalizados

Cesar Augusto Taconeli

30 de outubro, 2022

## Aula 4 - Família exponencial de distribuições

# Componente aleatório de um modelo linear generalizado

- O componente aleatório de um modelo linear generalizado consiste em uma variável aleatória  $y$ , por meio de um conjunto de observações independentes  $y_1, y_2, \dots, y_n$ , com distribuição pertencente à *família exponencial de distribuições*.

## Componente aleatório de um modelo linear generalizado

- O componente aleatório de um modelo linear generalizado consiste em uma variável aleatória  $y$ , por meio de um conjunto de observações independentes  $y_1, y_2, \dots, y_n$ , com distribuição pertencente à *família exponencial de distribuições*.
- Mais especificamente, assumimos que a função (densidade) de probabilidades de  $y$  possa ser expressa na forma:

$$f(y_i; \theta_i, \phi) = \exp \left\{ \frac{y_i \theta_i - b(\theta_i)}{\phi} + c(y_i; \phi) \right\},$$

sendo usualmente chamada de *forma canônica da família exponencial*, ou *família exponencial de dispersão*.

# Componente aleatório de um modelo linear generalizado

- O parâmetro  $\theta_i$  é chamado *parâmetro natural* (ou *parâmetro canônico*) e  $\phi$  o *parâmetro de dispersão* da distribuição.

# Componente aleatório de um modelo linear generalizado

- O parâmetro  $\theta_i$  é chamado *parâmetro natural* (ou *parâmetro canônico*) e  $\phi$  o *parâmetro de dispersão* da distribuição.
- A família exponencial contempla diversas distribuições uni e bi-paramétricas, por exemplo as distribuições binomial, poisson, normal, gama e normal inversa.

# Algumas propriedades da família exponencial de dispersão

- Para deduzir a esperança e a variância de uma variável aleatória com distribuição pertencente à família exponencial, recorreremos a alguns resultados da teoria da verossimilhança.

## Algumas propriedades da família exponencial de dispersão

- Para deduzir a esperança e a variância de uma variável aleatória com distribuição pertencente à família exponencial, recorreremos a alguns resultados da teoria da verossimilhança.
- Seja  $y$  uma única observação de  $f(y; \theta, \phi)$ . Sob condições de regularidade, atendidas pela família exponencial de dispersão, valem os seguintes resultados:

$$E \left\{ \frac{\partial \log f(y; \theta, \phi)}{\partial \theta} \right\} = 0; \quad (1)$$

$$E \left[ \left\{ \frac{\partial \log f(y; \theta, \phi)}{\partial \theta} \right\}^2 \right] = -E \left\{ \frac{\partial^2 \log f(y; \theta, \phi)}{\partial \theta^2} \right\}. \quad (2)$$



# Algumas propriedades da família exponencial de dispersão

- Usando os resultados (1) e (2), verifica-se que, para as distribuições pertencentes à família exponencial, tem-se  $E(y_i)$  e  $Var(y_i)$  dadas por:

$$E(y_i) = \mu_i = b'(\theta_i) = \frac{\partial b(\theta_i)}{\partial \theta_i}$$

# Algumas propriedades da família exponencial de dispersão

- Usando os resultados (1) e (2), verifica-se que, para as distribuições pertencentes à família exponencial, tem-se  $E(y_i)$  e  $Var(y_i)$  dadas por:

$$E(y_i) = \mu_i = b'(\theta_i) = \frac{\partial b(\theta_i)}{\partial \theta_i}$$

e

$$Var(y_i) = \phi \times b''(\theta_i) = \phi \times \frac{\partial \mu_i}{\partial \theta_i}.$$

# Algumas propriedades da família exponencial de dispersão

- Assim, a variância de  $y_i$  pode ser fatorada em dois componentes:

# Algumas propriedades da família exponencial de dispersão

- Assim, a variância de  $y_i$  pode ser fatorada em dois componentes:
  - O primeiro ( $\phi$ ) está associado exclusivamente à dispersão de  $y_i$  (não à sua média);

# Algumas propriedades da família exponencial de dispersão

- Assim, a variância de  $y_i$  pode ser fatorada em dois componentes:
  - O primeiro ( $\phi$ ) está associado exclusivamente à dispersão de  $y_i$  (não à sua média);
  - O segundo, usualmente denotado por  $V(\mu_i) = b''(\theta_i)$  e chamado *função de variância*, é função da média da distribuição, e exprime a relação variância-média de  $y$ .

# Algumas propriedades da família exponencial de dispersão

- Assim, a variância de  $y_i$  pode ser fatorada em dois componentes:
  - O primeiro ( $\phi$ ) está associado exclusivamente à dispersão de  $y_i$  (não à sua média);
  - O segundo, usualmente denotado por  $V(\mu_i) = b''(\theta_i)$  e chamado *função de variância*, é função da média da distribuição, e exprime a relação variância-média de  $y$ .
- Cada distribuição pertencente à família exponencial tem sua particular função de variância e vice-versa (teorema da unicidade das funções de variância).

# Algumas propriedades da família exponencial de dispersão

- A distribuição conjunta de  $y_1, y_2, \dots, y_n$  é dada por:

$$f(\mathbf{y}; \boldsymbol{\theta}, \phi) = \prod_{i=1}^n f(y_i; \theta_i, \phi) = \exp \left\{ \frac{\sum_{i=1}^n y_i \theta_i - \sum_{i=1}^n b(\theta_i)}{\phi} \right\} \\ \times \exp \sum_{i=1}^n c(y_i; \phi),$$

de maneira que, pelo teorema da fatoração de Neyman-Fisher, tem-se que  $\sum_{i=1}^n y_i$  é uma estatística suficiente para  $\theta_i$  se  $\phi$  for conhecido.

# Algumas propriedades da família exponencial de dispersão

- A distribuição conjunta de  $y_1, y_2, \dots, y_n$  é dada por:

$$f(\mathbf{y}; \boldsymbol{\theta}, \phi) = \prod_{i=1}^n f(y_i; \theta_i, \phi) = \exp \left\{ \frac{\sum_{i=1}^n y_i \theta_i - \sum_{i=1}^n b(\theta_i)}{\phi} \right\} \\ \times \exp \sum_{i=1}^n c(y_i; \phi),$$

de maneira que, pelo teorema da fatoração de Neyman-Fisher, tem-se que  $\sum_{i=1}^n y_i$  é uma estatística suficiente para  $\theta_i$  se  $\phi$  for conhecido.

- Na sequência são ilustradas algumas distribuições pertencentes à família exponencial.



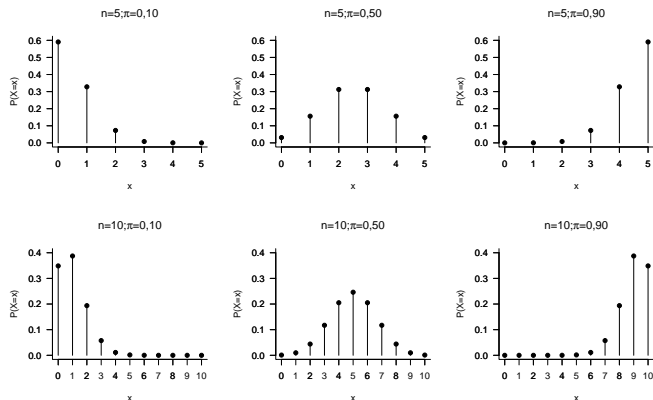
# Distribuição binomial

- Uma variável aleatória  $x_i$  tem distribuição binomial se sua função de probabilidades é dada por:

$$f(x_i; n_i, \pi_i) = \binom{n_i}{x_i} \pi_i^{x_i} (1 - \pi_i)^{n_i - x_i}; \quad x_i = 0, 1, 2, \dots, n_i; \quad 0 < \pi_i < 1,$$

em que  $x_i$  corresponde à contagem de *sucessos* em  $n_i$  observações independentes de um experimento binário.

# Distribuição binomial



**Figura 1:** Ilustração - distribuição binomial

# Distribuição binomial

- Podemos expressar a distribuição binomial, de maneira alternativa, pela variável  $y_i = \frac{x_i}{n_i}$ , a fração amostral de sucessos, com função de probabilidades:

$$f(y_i; n_i, \pi_i) = \binom{n_i}{n_i y_i} \pi_i^{n_i y_i} (1 - \pi_i)^{n_i - (n_i y_i)}; y_i = 0, \frac{1}{n_i}, \frac{2}{n_i}, \dots, 1; 0 < \pi_i < 1.$$

# Distribuição binomial (gabarito)

- Neste caso, temos que:

- $\theta_i = \log\left(\frac{\pi_i}{1-\pi_i}\right), b(\theta_i) = \log(1 + e^{\theta_i});$

# Distribuição binomial (gabarito)

- Neste caso, temos que:

- $\theta_i = \log \left( \frac{\pi_i}{1-\pi_i} \right), b(\theta_i) = \log(1 + e^{\theta_i});$

- $\phi = \frac{1}{n_i}, c(y_i, \phi) = \binom{n_i}{y_i};$

# Distribuição binomial (gabarito)

- Neste caso, temos que:

- $\theta_i = \log \left( \frac{\pi_i}{1-\pi_i} \right), b(\theta_i) = \log(1 + e^{\theta_i});$

- $\phi = \frac{1}{n_i}, c(y_i, \phi) = \binom{n_i}{y_i};$

- $E(y_i) = \mu_i = b'(\theta_i) = \pi_i;$

# Distribuição binomial (gabarito)

- Neste caso, temos que:

- $\theta_i = \log \left( \frac{\pi_i}{1-\pi_i} \right), b(\theta_i) = \log(1 + e^{\theta_i});$

- $\phi = \frac{1}{n_i}, c(y_i, \phi) = \binom{n_i}{y_i};$

- $E(y_i) = \mu_i = b'(\theta_i) = \pi_i;$

- $V(\mu_i) = b''(\theta_i) = \mu_i(1 - \mu_i);$

# Distribuição binomial (gabarito)

- Neste caso, temos que:

- $\theta_i = \log\left(\frac{\pi_i}{1-\pi_i}\right), b(\theta_i) = \log(1 + e^{\theta_i});$

- $\phi = \frac{1}{n_i}, c(y_i, \phi) = \binom{n_i}{y_i};$

- $E(y_i) = \mu_i = b'(\theta_i) = \pi_i;$

- $V(\mu_i) = b''(\theta_i) = \mu_i(1 - \mu_i);$

- $Var(y_i) = \frac{\mu_i(1-\mu_i)}{n_i}.$



# Distribuição binomial

- Algumas notas sobre a distribuição binomial:

# Distribuição binomial

- Algumas notas sobre a distribuição binomial:
  - A distribuição binomial é usada, principalmente, na modelagem de dados binários ou de proporções discretas;

# Distribuição binomial

- Algumas notas sobre a distribuição binomial:
  - A distribuição binomial é usada, principalmente, na modelagem de dados binários ou de proporções discretas;
  - É bem aproximada pela distribuição  $Normal(\pi, \frac{\pi(1-\pi)}{m})$  quando  $m\pi > 0.5$  e  $0.1 \leq \pi \leq 0.9$  ou  $m\pi > 25$ , para qualquer valor de  $\pi$ .

# Distribuição Poisson

- Uma variável aleatória discreta  $y_i$  tem distribuição de Poisson se sua função de probabilidades é dada por:

$$f(y_i; \mu_i) = \frac{e^{-\mu_i} \mu_i^{y_i}}{y_i!},$$

com  $y_i = 0, 1, 2, \dots; \mu_i > 0$ .

# Distribuição Poisson (gabarito)

- Neste caso, temos que:

# Distribuição Poisson (gabarito)

- Neste caso, temos que:

- $\theta_i = \log(\mu_i), b(\theta_i) = e^{\theta_i};$

# Distribuição Poisson (gabarito)

- Neste caso, temos que:

- $\theta_i = \log(\mu_i), b(\theta_i) = e^{\theta_i};$

- $\phi = 1, c(y_i, \phi) = -\log(y_i!);$

# Distribuição Poisson (gabarito)

- Neste caso, temos que:

- $\theta_i = \log(\mu_i), b(\theta_i) = e^{\theta_i};$

- $\phi = 1, c(y_i, \phi) = -\log(y_i!);$

- $E(y_i) = b'(\theta_i) = \mu_i;$



# Distribuição Poisson (gabarito)

• Neste caso, temos que:


- $\theta_i = \log(\mu_i), b(\theta_i) = e^{\theta_i};$
- $\phi = 1, c(y_i, \phi) = -\log(y_i!);$
- $E(y_i) = b'(\theta_i) = \mu_i;$
- $V(\mu_i) = b''(\theta_i) = \mu_i;$

# Distribuição Poisson (gabarito)

• Neste caso, temos que:

- $\theta_i = \log(\mu_i), b(\theta_i) = e^{\theta_i};$
- $\phi = 1, c(y_i, \phi) = -\log(y_i!);$
- $E(y_i) = b'(\theta_i) = \mu_i;$
- $V(\mu_i) = b''(\theta_i) = \mu_i;$
- $Var(y_i) = \phi V(\mu_i) = \mu_i.$

# Distribuição Poisson



**Figura 2:** Ilustração - distribuição de Poisson

# Distribuição Poisson

- Algumas notas sobre a distribuição de Poisson:

# Distribuição Poisson

- Algumas notas sobre a distribuição de Poisson:
  - Se eventos ocorrem independente e aleatoriamente no tempo (ou espaço), com taxa média de ocorrência constante, a distribuição atribui probabilidades ao número de eventos por intervalo de tempo (ou região do espaço);

# Distribuição Poisson

- Algumas notas sobre a distribuição de Poisson:
  - Se eventos ocorrem independente e aleatoriamente no tempo (ou espaço), com taxa média de ocorrência constante, a distribuição atribui probabilidades ao número de eventos por intervalo de tempo (ou região do espaço);
  - Proporciona, em geral, uma descrição satisfatória de dados cuja variância é proporcional à média;

# Distribuição Poisson

- Algumas notas sobre a distribuição de Poisson:
  - Se eventos ocorrem independente e aleatoriamente no tempo (ou espaço), com taxa média de ocorrência constante, a distribuição atribui probabilidades ao número de eventos por intervalo de tempo (ou região do espaço);
  - Proporciona, em geral, uma descrição satisfatória de dados cuja variância é proporcional à média;
  - Surge como caso limite para a distribuição binomial quando  $n \rightarrow \infty$  e  $\pi \rightarrow 0$  (matendo fixo  $\mu = n\pi$ );

# Distribuição Poisson

- Algumas notas sobre a distribuição de Poisson:
  - Se eventos ocorrem independente e aleatoriamente no tempo (ou espaço), com taxa média de ocorrência constante, a distribuição atribui probabilidades ao número de eventos por intervalo de tempo (ou região do espaço);
  - Proporciona, em geral, uma descrição satisfatória de dados cuja variância é proporcional à média;
  - Surge como caso limite para a distribuição binomial quando  $n \rightarrow \infty$  e  $\pi \rightarrow 0$  (mantendo fixo  $\mu = n\pi$ );
  - É bem aproximada pela distribuição  $Normal(\mu, \mu)$  para  $\mu$  suficientemente grande.



# Distribuição normal

- Uma variável aleatória contínua  $y_i$  tem distribuição normal se sua função densidade de probabilidade é dada por:

$$f(y_i; \mu_i, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{(y_i - \mu_i)^2}{2\sigma^2} \right\},$$

com  $-\infty < y_i < \infty$ ;  $-\infty < \mu_i < \infty$ ;  $\sigma > 0$ .

# Distribuição Normal (gabarito)

- Neste caso, temos que:

# Distribuição Normal (gabarito)

- Neste caso, temos que:

- $\theta_i = \mu_i, b(\theta_i) = \frac{\theta_i^2}{2};$

# Distribuição Normal (gabarito)

- Neste caso, temos que:

- $\theta_i = \mu_i, b(\theta_i) = \frac{\theta_i^2}{2};$

- $\phi = \sigma^2, c(y_i, \phi) = -\frac{1}{2} \left[ \frac{y_i^2}{\sigma^2} + \log(2\pi\sigma^2) \right]$

# Distribuição Normal (gabarito)

- Neste caso, temos que:

- $\theta_i = \mu_i, b(\theta_i) = \frac{\theta_i^2}{2};$

- $\phi = \sigma^2, c(y_i, \phi) = -\frac{1}{2} \left[ \frac{y_i^2}{\sigma^2} + \log(2\pi\sigma^2) \right]$

- $E(y_i) = b'(\theta_i) = \mu_i;$

# Distribuição Normal (gabarito)

- Neste caso, temos que:

- $\theta_i = \mu_i, b(\theta_i) = \frac{\theta_i^2}{2};$

- $\phi = \sigma^2, c(y_i, \phi) = -\frac{1}{2} \left[ \frac{y_i^2}{\sigma^2} + \log(2\pi\sigma^2) \right]$

- $E(y_i) = b'(\theta_i) = \mu_i;$

- $V(\mu_i) = b''(\theta_i) = 1;$

# Distribuição Normal (gabarito)

- Neste caso, temos que:

- $\theta_i = \mu_i, b(\theta_i) = \frac{\theta_i^2}{2};$

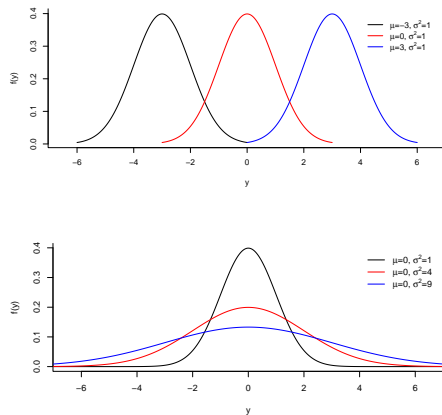
- $\phi = \sigma^2, c(y_i, \phi) = -\frac{1}{2} \left[ \frac{y_i^2}{\sigma^2} + \log(2\pi\sigma^2) \right]$

- $E(y_i) = b'(\theta_i) = \mu_i;$

- $V(\mu_i) = b''(\theta_i) = 1;$

- $Var(y_i) = \phi V(\mu_i) = \sigma^2.$

# Distribuição normal



**Figura 3:** Ilustração - distribuição normal



## Distribuição gama

- Uma variável aleatória contínua  $y_i$  tem distribuição gama se sua função densidade de probabilidade é dada por:

$$f(y_i; \mu_i, \nu) = \frac{\left(\frac{\nu}{\mu_i}\right)^\nu}{\Gamma(\nu)} y_i^{\nu-1} \exp\left\{-\frac{y_i \nu}{\mu_i}\right\},$$

com  $y_i > 0$ ,  $\mu_i > 0$ ,  $\nu > 0$  e  $\Gamma(x) = \int_0^\infty t^{x-1} e^{-t} dt$ .

## Distribuição gama

- Uma variável aleatória contínua  $y_i$  tem distribuição gama se sua função densidade de probabilidade é dada por:

$$f(y_i; \mu_i, \nu) = \frac{\left(\frac{\nu}{\mu_i}\right)^\nu}{\Gamma(\nu)} y_i^{\nu-1} \exp\left\{-\frac{y_i \nu}{\mu_i}\right\},$$

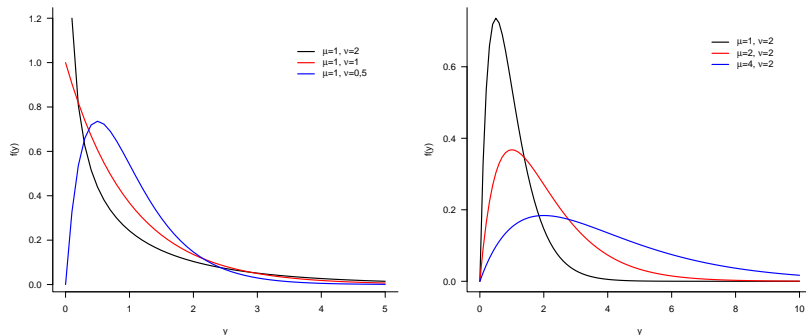
com  $y_i > 0$ ,  $\mu_i > 0$ ,  $\nu > 0$  e  $\Gamma(x) = \int_0^\infty t^{x-1} e^{-t} dt$ .

- Uma das parametrizações alternativas da distribuição gama é a seguinte:

$$f(y; \alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} y^{\alpha-1} \exp\{-\beta y\},$$

tal que a equivalência das duas parametrizações decorre de  $\mu = \frac{\alpha}{\beta}$  e  $\nu = \alpha$ .

# Distribuição gama



**Figura 4:** Ilustração - distribuição gama

# Distribuição gama

- A distribuição gama é usada na análise de dados contínuos não negativos em que a variância aumenta conforme a média, particularmente no caso em que o coeficiente de variação é aproximadamente constante.

# Distribuição gama (gabarito)

- Neste caso, temos que:

# Distribuição gama (gabarito)

- Neste caso, temos que:

- $\theta_i = -\frac{1}{\mu_i}, b(\theta_i) = -\log(-\theta_i);$

# Distribuição gama (gabarito)

- Neste caso, temos que:

- $\theta_i = -\frac{1}{\mu_i}, b(\theta_i) = -\log(-\theta_i);$

- $\phi = \nu^{-1}, c(y_i, \phi) = \nu \log(\nu y_i) - \log(y_i) - \log(\Gamma(\nu))$

# Distribuição gama (gabarito)

- Neste caso, temos que:

- $\theta_i = -\frac{1}{\mu_i}$ ,  $b(\theta_i) = -\log(-\theta_i)$ ;

- $\phi = \nu^{-1}$ ,  $c(y_i, \phi) = \nu \log(\nu y_i) - \log(y_i) - \log(\Gamma(\nu))$

- $E(y_i) = b'(\theta_i) = \mu_i$ ;



# Distribuição gama (gabarito)

- Neste caso, temos que:

- $\theta_i = -\frac{1}{\mu_i}, b(\theta_i) = -\log(-\theta_i);$

- $\phi = \nu^{-1}, c(y_i, \phi) = \nu \log(\nu y_i) - \log(y_i) - \log(\Gamma(\nu))$

- $E(y_i) = b'(\theta_i) = \mu_i;$

- $V(\mu_i) = b''(\theta_i) = \mu_i^2;$

# Distribuição gama (gabarito)

- Neste caso, temos que:

- $\theta_i = -\frac{1}{\mu_i}, b(\theta_i) = -\log(-\theta_i);$

- $\phi = \nu^{-1}, c(y_i, \phi) = \nu \log(\nu y_i) - \log(y_i) - \log(\Gamma(\nu))$

- $E(y_i) = b'(\theta_i) = \mu_i;$

- $V(\mu_i) = b''(\theta_i) = \mu_i^2;$

- $Var(y_i) = \phi V(\mu_i) = \nu^{-1} \mu_i^2.$


# Distribuição normal inversa

- Uma variável aleatória contínua tem distribuição normal inversa se sua função densidade de probabilidade é dada por:

$$f(y_i; \mu_i, \tau) = \sqrt{\frac{\tau}{2\pi y_i^3}} \exp \left\{ -\frac{\tau (y_i - \mu_i)^2}{2\mu_i^2 y_i} \right\},$$

com  $y_i > 0$ ,  $\mu_i > 0$ ,  $\tau > 0$ .

# Distribuição normal inversa



**Figura 5:** Ilustração - distribuição normal inversa

# Distribuição normal inversa

- A distribuição normal inversa se aplica a análise de dados contínuos, não negativos com distribuição acentuadamente assimétrica.

# Distribuição normal inversa (gabarito)

- Neste caso, temos que:

- $\theta_i = -\frac{1}{2\mu_i^2}, b(\theta_i) = -(-2\theta_i)^{1/2};$

# Distribuição normal inversa (gabarito)

- Neste caso, temos que:

- $\theta_i = -\frac{1}{2\mu_i^2}$ ,  $b(\theta_i) = -(-2\theta_i)^{1/2}$ ;

- $\phi = 1/\tau$ ,  $c(\phi, y) = -\frac{1}{2} \left[ \log \left( 2\pi y^3 + \frac{1}{\phi y} \right) \right]$

# Distribuição normal inversa (gabarito)

- Neste caso, temos que:

- $\theta_i = -\frac{1}{2\mu_i^2}$ ,  $b(\theta_i) = -(-2\theta_i)^{1/2}$ ;

- $\phi = 1/\tau$ ,  $c(\phi, y) = -\frac{1}{2} \left[ \log \left( 2\pi y^3 + \frac{1}{\phi y} \right) \right]$

- $E(y_i) = b'(\theta_i) = \mu_i$ ;



# Distribuição normal inversa (gabarito)

- Neste caso, temos que:

- $\theta_i = -\frac{1}{2\mu_i^2}$ ,  $b(\theta_i) = -(-2\theta_i)^{1/2}$ ;

- $\phi = 1/\tau$ ,  $c(\phi, y) = -\frac{1}{2} \left[ \log \left( 2\pi y^3 + \frac{1}{\phi y} \right) \right]$

- $E(y_i) = b'(\theta_i) = \mu_i$ ;

- $V(\mu_i) = b''(\theta_i) = \mu_i^3$ ;

# Distribuição normal inversa (gabarito)

- Neste caso, temos que:

- $\theta_i = -\frac{1}{2\mu_i^2}$ ,  $b(\theta_i) = -(-2\theta_i)^{1/2}$ ;

- $\phi = 1/\tau$ ,  $c(\phi, y) = -\frac{1}{2} \left[ \log \left( 2\pi y^3 + \frac{1}{\phi y} \right) \right]$

- $E(y_i) = b'(\theta_i) = \mu_i$ ;

- $V(\mu_i) = b''(\theta_i) = \mu_i^3$ ;

- $Var(y_i) = \tau V(\mu_i) = \tau \mu_i^3$ .

# Distribuição binomial negativa

- Uma variável aleatória discreta  $Y$  tem distribuição binomial negativa se a sua função de probabilidades é dada por:

$$f(y_i; \mu_i, k) = \frac{\Gamma(k + y_i)}{\Gamma(k)y_i!} \frac{\mu_i^{y_i} k^k}{(\mu_i + k)^{k+y_i}},$$

com  $y_i = 0, 1, 2, \dots$ ;  $\mu_i > 0$ ;  $k > 0$ .

# Distribuição binomial negativa

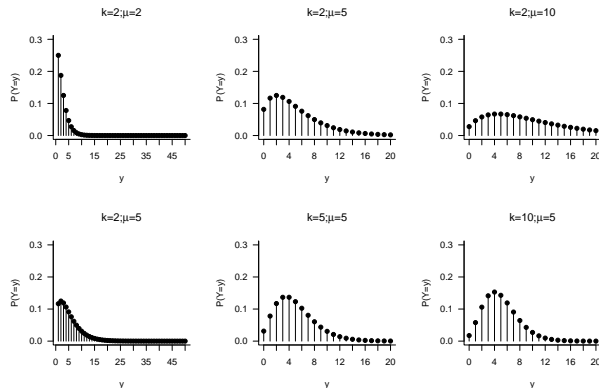


Figura 6: Ilustração - distribuição binomial negativa

# Distribuição binomial negativa

- A distribuição binomial negativa é uma alternativa ao de Poisson em situações em que a variância dos dados aumenta mais rapidamente que a média;

# Distribuição binomial negativa

- A distribuição binomial negativa é uma alternativa ao de Poisson em situações em que a variância dos dados aumenta mais rapidamente que a média;
- Para valores inteiros de  $k$ , usa-se a denominação *distribuição de Pascal*;

# Distribuição binomial negativa

- A distribuição binomial negativa é uma alternativa ao de Poisson em situações em que a variância dos dados aumenta mais rapidamente que a média;
- Para valores inteiros de  $k$ , usa-se a denominação *distribuição de Pascal*;
- Para  $k = 1$ , temos como caso particular a distribuição geométrica.

## Distribuição binomial negativa (gabarito)

- Neste caso, temos que:

- $\theta_i = \log \left( \frac{\mu_i}{\mu_i + k} \right), b(\theta_i) = -k \log(1 + e^{\theta_i});$



# Distribuição binomial negativa (gabarito)

- Neste caso, temos que:

- $\theta_i = \log \left( \frac{\mu_i}{\mu_i + k} \right), b(\theta_i) = -k \log(1 + e^{\theta_i});$

- $\phi = 1, c(y_i, \phi) = \log \left[ \frac{\Gamma(k + y_i)}{\Gamma(k) y_i!} \right];$

# Distribuição binomial negativa (gabarito)

- Neste caso, temos que:

- $\theta_i = \log \left( \frac{\mu_i}{\mu_i + k} \right), b(\theta_i) = -k \log(1 + e^{\theta_i});$

- $\phi = 1, c(y_i, \phi) = \log \left[ \frac{\Gamma(k + y_i)}{\Gamma(k) y_i!} \right];$

- $\mu_i = b'(\theta_i) = \mu_i;$

# Distribuição binomial negativa (gabarito)

- Neste caso, temos que:

- $\theta_i = \log \left( \frac{\mu_i}{\mu_i + k} \right), b(\theta_i) = -k \log(1 + e^{\theta_i});$

- $\phi = 1, c(y_i, \phi) = \log \left[ \frac{\Gamma(k + y_i)}{\Gamma(k) y_i!} \right];$

- $\mu_i = b'(\theta_i) = \mu_i;$

- $V(\mu_i) = b''(\theta_i) = \mu_i \left( \frac{\mu_i}{k} + 1 \right);$

# Distribuição binomial negativa (gabarito)

- Neste caso, temos que:

- $\theta_i = \log \left( \frac{\mu_i}{\mu_i + k} \right), b(\theta_i) = -k \log(1 + e^{\theta_i});$

- $\phi = 1, c(y_i, \phi) = \log \left[ \frac{\Gamma(k + y_i)}{\Gamma(k) y_i!} \right];$

- $\mu_i = b'(\theta_i) = \mu_i;$

- $V(\mu_i) = b''(\theta_i) = \mu_i \left( \frac{\mu_i}{k} + 1 \right);$

- $Var(y_i) = \mu_i \left( \frac{\mu_i}{k} + 1 \right).$