

Universidade Federal do Paraná - Departamento de Estatística
CE225: Modelos lineares generalizados
Prof. Cesar Augusto Taconeli
Material complementar

Propriedades- família exponencial

Seja y uma observação da variável aleatória Y , cuja função (densidade) de probabilidade pode ser expressa na forma:

$$f(y|\theta, \phi) = \exp \left\{ \frac{\theta y - b(\theta)}{\phi} + c(y; \phi) \right\}, \quad (1)$$

sendo θ e ϕ denominados parâmetros canônico e de dispersão da distribuição, respectivamente.

Vamos derivar a média (esperança) de Y . Para isso, vamos considerar a função de log-verossimilhança fica dada por:

$$l(\theta, \phi|y) = \frac{\theta y - b(\theta)}{\phi} + c(y; \phi) \quad (2)$$

A função escore é definida pelas derivadas da log-verossimilhança com relação aos parâmetros do modelo. No caso:

$$S(\theta) = \frac{\partial l(\theta, \phi|y)}{\partial \theta}, \quad (3)$$

e em suas propriedades, como detalhado na sequência.

$$E(S(\theta)) = 0 \quad (4)$$

$$\begin{aligned} \text{Var}(S(\theta)) &= E[S(\theta)^2] - \{E[S(\theta)]\}^2 = \\ &= E[S(\theta)^2] = \\ &= \left(\frac{\partial}{\partial \theta} l(\theta, \phi|y) \right)^2, \end{aligned}$$

e, conforme iremos verificar adiante,

$$\left(\frac{\partial}{\partial \theta} l(\theta, \phi|y) \right)^2 = -E \left[\frac{\partial^2}{\partial \theta^2} l(\theta, \phi|y) \right] \quad (5)$$

Essas propriedades da função escore, que valem em geral sob certas condições de regularidade, também serão demonstradas adiante.

Média e variância das distribuições pertencentes à família exponencial

Para o caso de Y com distribuição pertencente à família exponencial, com base na função (densidade) de probabilidade definida em (1), e na definição da função escore (3) e de suas propriedades apresentadas em (4) e (5), vamos derivar, inicialmente, a média de Y :

$$\begin{aligned} E(S(\theta)) &= E \left[\frac{\partial}{\partial \theta} l(\theta, \phi|y) \right] = \\ &= E \left[\frac{\partial}{\partial \theta} \frac{\theta Y - b(\theta)}{\phi} \right] = \\ &= E \left[\frac{Y - b'(\theta)}{\phi} \right]. \end{aligned} \tag{6}$$

Lembrando que $E(S(\theta)) = 0$, podemos deduzir, temos que:

$$E \left[\frac{Y - b'(\theta)}{\phi} \right] = 0,$$

de onde podemos extrair que:

$$E(Y) = b'(\theta) = \frac{\partial}{\partial \theta} b(\theta) \tag{7}$$

Agora, vamos obter a variância de Y . Neste caso:

$$\text{Var}(S(\theta)) = E \left[\left(\frac{\partial}{\partial \theta} l(\theta, \phi|y) \right)^2 \right] = -E \left[\frac{\partial^2}{\partial \theta^2} l(\theta, \phi|y) \right] \tag{8}$$

Vamos trabalhar cada membro dessa igualdade. Primeiramente:

$$\begin{aligned} E \left[\left(\frac{\partial}{\partial \theta} l(\theta, \phi|y) \right)^2 \right] &= E \left[\left(\frac{\partial}{\partial \theta} \frac{Y - b'(\theta)}{\phi} \right)^2 \right] = \\ &= \frac{EY^2 - 2E(Y)b'(\theta) + [b'(\theta)]^2}{\phi^2} = \\ &= \frac{E(Y^2) - [E(Y)]^2}{\phi^2} = \frac{\text{Var}(Y)}{\phi^2} \end{aligned} \tag{9}$$

Agora, tomando o membro à direita em (8):

$$\begin{aligned} -E \left[\frac{\partial^2}{\partial \theta^2} l(\theta, \phi|y) \right] &= -E \left[\frac{\partial}{\partial \theta} \left(\frac{Y - b'(\theta)}{\phi} \right) \right] \\ &= -E \left[\frac{-b''(\theta)}{\phi} \right] = \frac{b''(\theta)}{\phi} \end{aligned}$$

Agora, retornando à igualdade em (8), temos:

$$E \left(\frac{\partial}{\partial \theta} l(\theta, \phi|y) \right)^2 = -E \left[\frac{\partial^2}{\partial \theta^2} l(\theta, \phi|y) \right]$$

$$\frac{\text{Var}(Y)}{\phi^2} = \frac{b''(\theta)}{\phi}$$

De onde se extrai:

$$\text{Var}(Y) = \phi b''(\theta)$$

Note que:

$$\text{Var}(Y) = \phi b''(\theta) =$$

$$\phi \frac{\partial}{\partial \theta} b'(\theta) =$$

$$\phi \frac{\partial}{\partial \theta} \mu =$$

$$\phi V(\mu),$$

onde $V(\mu)$ é chamada função de variância, que descreve a relação entre média e variância para as distribuições pertencentes à família exponencial.

Complemento- Propriedades gerais da função escore

- Média (esperança) da função escore.

$$E(S(\theta)) = \int_Y S(\theta) f(y|\theta, \phi) dy =$$

$$\int_Y \left[\frac{\partial}{\partial \theta} \log(f(y|\theta, \phi)) \right] f(y|\theta, \phi) dy =$$

$$\int_Y \frac{1}{f(y|\theta, \phi)} \left[\frac{\partial}{\partial \theta} f(y|\theta, \phi) \right] f(y|\theta, \phi) dy =$$

$$\int_Y \frac{\partial}{\partial \theta} f(y|\theta, \phi) dy$$

As distribuições que pertencem à família exponencial atendem a condições de regularidade que permitem intercambiar operações de derivação e integração. Desta forma:

$$\begin{aligned}
E(S(\theta)) &= \int_Y \frac{\partial f(y|\theta, \phi)}{\partial \theta} dy = \\
&\frac{\partial}{\partial \theta} \int_Y f(y|\theta, \phi) dy = \\
&\frac{\partial}{\partial \theta} 1 = 0
\end{aligned}$$

- Variância da função escore.

$$\text{Var}(S(\theta)) = E[S(\theta)^2] - \{E[S(\theta)]\}^2$$

Como verificado anteriormente, $E[S(\theta)] = 0$, de maneira que $\{E[S(\theta)]\}^2 = 0$ e, consequentemente:

$$\begin{aligned}
\text{Var}(S(\theta)) &= E[S(\theta)^2] = \\
&E\left[\left(\frac{\partial}{\partial \theta} l(\theta, \phi|y)\right)^2\right] = \\
&\int_Y \left(\frac{\partial}{\partial \theta} l(\theta, \phi|y)\right)^2 f(y|\theta, \phi) dy,
\end{aligned}$$

que é a informação de Fisher relativa a θ , que pode ser expressa como:

$$I(\theta) = -E\left[\frac{\partial^2}{\partial \theta^2} l(\theta, \phi|y)\right]$$

uma vez que

$$\begin{aligned}
\frac{\partial^2}{\partial \theta^2} l(\theta, \phi|y) &= \frac{\partial}{\partial \theta} \left[\frac{f'(y; \theta, \phi)}{f(y; \theta, \phi)} \right] = \\
&\frac{1}{f(y; \theta, \phi)} f''(y; \theta, \phi) - \left[\frac{f(y; \theta, \phi)}{[f(y; \theta, \phi)]^2} f'(y; \theta, \phi) + \frac{1}{f(y; \theta, \phi)} f''(y; \theta, \phi) \right] = \\
&\left[\frac{f''(y; \theta, \phi)}{f(y; \theta, \phi)} \right]^2 = \\
&\left[\frac{\partial}{\partial \theta} l(\theta, \phi|y) \right]^2
\end{aligned}$$

Logo,

$$I(\theta) = E\left(\frac{\partial}{\partial \theta} \log f(y|\theta, \phi)\right)^2 = -E\left[\frac{\partial^2}{\partial \theta^2} \log f(y|\theta, \phi)\right].$$

Principais membros da família exponencial

- **Distribuição binomial**

Seja $X \sim \text{binomial}(m, \pi)$, com função de probabilidades dada por:

$$f_X(x|m, \pi) = \binom{m}{x} \pi^x (1 - \pi)^{m-x}, \quad m \in \mathbb{N}; 0 < \pi < 1; x = 0, 1, \dots, m$$

O modelo apresentado representa o número de sucessos y em m ensaios independentes de Bernoulli, cada um com probabilidade de sucesso p . De maneira alternativa, podemos definir a fração de sucessos $Y = X/m$, de forma que a função de probabilidades fica dada por:

$$\begin{aligned} f_Y(y|m, \pi) &= \binom{m}{my} p^{my} (1 - \pi)^{m-my} = \\ &\exp \left\{ my \log \left(\frac{\pi}{1 - \pi} \right) + m \log(1 - \pi) + \log \binom{m}{my} \right\} = \\ &\exp \left\{ m \left[y \log \left(\frac{\pi}{1 - \pi} \right) + \log(1 - \pi) \right] + \log \binom{m}{my} \right\}, \end{aligned}$$

de onde podemos extrair:

$$\theta = \log \frac{\pi}{1 - \pi} \rightarrow \pi = \frac{e^\theta}{e^\theta + 1}$$

$$b(\theta) = -\log(1 - \pi) = -\log \left(1 - \frac{e^\theta}{e^\theta + 1} \right) =$$

$$\log(1 + e^\theta)$$

$$\phi = \frac{1}{m}$$

$$c(y; \phi) = \log \binom{m}{my}$$

$$E(Y) = \mu = b'(\theta) = \frac{\partial}{\partial \theta} \log(1 + e^\theta) = \frac{e^\theta}{e^\theta + 1} = \pi$$

$$b''(\theta) = \frac{e^\theta (e^\theta + 1) - (e^\theta)^2}{(e^\theta + 1)^2} =$$

$$\frac{e^\theta}{(e^\theta + 1)^2} =$$

$$\mu(1 - \mu),$$

de tal forma que:

$$V(\mu) = b''(\theta) = \mu(1 - \mu),$$

e

$$\text{Var}(Y) = \phi b''(\theta) = \frac{\mu(1 - \mu)}{m}.$$

- **Distribuição de Poisson**

Seja $Y \sim \text{Poisson}(\mu)$, com função de probabilidades dada por:

$$f_Y(y; \mu) = \frac{e^{-\mu} \mu^y}{y!}, \quad y = 0, 1, 2, \dots; \mu > 0$$

Logo,

$$\begin{aligned} f_Y(y; \mu) &= \frac{e^{-\mu} \mu^y}{y!} = \\ &\exp \left\{ \log \left(\frac{e^{-\mu} \mu^y}{y!} \right) \right\} = \\ &\exp \{ y \log(\mu) - \mu - \log y! \}, \end{aligned}$$

de tal forma que:

$$\theta = \log(\mu)$$

$$b(\theta) = \mu = e^\theta$$

$$\phi = 1$$

$$c(\phi, y) = -\log(y!)$$

$$E(Y) = b'(\theta) = \mu = e^\theta$$

$$V(\mu) = b''(\theta) = e^\theta = \mu$$

$$\text{Var}(Y) = \phi b''(\theta) = e^\theta = \mu$$

- **Distribuição normal**

Seja $Y \sim \text{normal}(\mu, \sigma^2)$, com função densidade de probabilidades dada por:

$$f_Y(y; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{1}{2\sigma^2} (y - \mu)^2 \right\}, \quad y \in \mathbb{R}; \mu \in \mathbb{R}; \sigma^2 > 0.$$

Desta forma,

$$\begin{aligned} f_Y(y; \mu) &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{1}{2\sigma^2} (y - \mu)^2 \right\} = \\ &= \exp \left\{ \log \left[\frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{1}{2\sigma^2} (y - \mu)^2 \right\} \right] \right\} = \\ &= \exp \left\{ -\frac{1}{2\sigma^2} (y^2 - 2\mu y + \mu^2) - \frac{1}{2} \log(2\pi\sigma^2) \right\} = \\ &= \exp \left\{ \frac{1}{\sigma^2} \left(\mu y - \frac{\mu^2}{2} \right) - \frac{y^2}{2\sigma^2} - \frac{1}{2} \log(2\pi\sigma^2) \right\}, \end{aligned}$$

tal que:

$$\theta = \mu$$

$$b(\theta) = \frac{\mu^2}{2} = \frac{\theta^2}{2}$$

$$\phi = \sigma^2$$

$$c(\phi, y) = -\frac{y^2}{2\sigma^2} - \frac{1}{2} \log(2\pi\sigma^2)$$

$$E(Y) = b'(\theta) = \theta = \mu$$

$$V(\mu) = b''(\theta) = 1$$

$$\text{Var}(Y) = \phi b''(\theta) = \sigma^2 \times 1 = \sigma^2$$

- **Distribuição gama**

Seja $Y \sim \text{gama}(\mu, \nu)$, com função densidade de probabilidades dada por:

$$f_Y(y; \mu, \nu) = \frac{\left(\frac{\nu}{\mu}\right)^\nu}{\Gamma(\nu)} y^{\nu-1} \exp\left\{-\frac{y\nu}{\mu}\right\}, \quad y > 0, \mu > 0, \nu > 0.$$

Desta forma,

$$\begin{aligned} f_Y(y; \mu, \nu) &= \frac{\left(\frac{\nu}{\mu}\right)^\nu}{\Gamma(\nu)} y^{\nu-1} \exp\left\{-\frac{y\nu}{\mu}\right\} = \\ &\exp\left\{\log\left(\frac{\left(\frac{\nu}{\mu}\right)^\nu}{\Gamma(\nu)} y^{\nu-1} \exp\left\{-\frac{y\nu}{\mu}\right\}\right)\right\} = \\ &\exp\left\{\nu \log\left(\frac{\nu}{\mu}\right) - \log(\Gamma(\nu)) + (\nu-1) \log(y) - \frac{y\nu}{\mu}\right\} = \\ &\exp\left\{\nu \left(-\frac{y}{\mu} - \log(\mu) + \log(\nu) - \log(\Gamma(\nu) + (\nu-1) \log(y))\right)\right\}, \end{aligned}$$

podendo-se deduzir que:

$$\theta = -\frac{1}{\mu}$$

$$b(\theta) = \log(\mu) = \log\left(-\frac{1}{\theta}\right) = -\log(-\theta)$$

$$\phi = \frac{1}{\nu}$$

$$c(\phi, y) = \log(\nu) - \log(\Gamma(\nu)) + (\nu-1) \log(y)$$

$$E(Y) = b'(\theta) = -\frac{1}{\theta} = \mu$$

$$V(\mu) = b''(\theta) = \frac{1}{\theta^2} = \mu^2$$

$$\text{Var}(Y) = \phi b''(\theta) = \frac{\mu^2}{\nu}$$

- **Distribuição normal inversa**

Seja $Y \sim \text{normal inversa}(\mu, \tau)$, com função densidade de probabilidades dada por:

$$f_Y(y; \mu, \tau) = \frac{\tau^{\frac{1}{2}}}{\sqrt{2\pi y^3}} \exp \left\{ -\frac{\tau(y - \mu)^2}{2\mu^2 y} \right\}, \quad y > 0; \mu > 0; \tau > 0$$

Desta forma,

$$\begin{aligned} f_Y(y; \mu, \tau) &= \frac{\tau^{\frac{1}{2}}}{\sqrt{2\pi y^3}} \exp \left\{ -\frac{\tau(y - \mu)^2}{2\mu^2 y} \right\} = \\ &= \exp \left\{ \log \left(\frac{\tau^{\frac{1}{2}}}{\sqrt{2\pi y^3}} \exp \left\{ -\frac{\tau(y - \mu)^2}{2\mu^2 y} \right\} \right) \right\} = \\ &= \exp \left\{ \tau \left[-\frac{y}{2\mu^2} + \frac{1}{\mu} \right] - \frac{1}{2} \left[\log \left(\frac{2\pi y^3}{\tau} \right) + \frac{\tau}{y} \right] \right\}, \end{aligned}$$

de onde podemos extrair que:

$$\theta = -\frac{1}{2\mu^2}$$

$$b(\theta) = -\frac{1}{\mu} = -\sqrt{-2\theta}$$

$$\phi = \frac{1}{\tau}$$

$$c(\tau, y) = -\frac{1}{2} \left[\log \left(\frac{2\pi y^3}{\tau} + \frac{\tau}{y} \right) \right]$$

$$E(Y) = b'(\theta) = 2 \times \frac{1}{2} (-2\theta)^{-\frac{1}{2}} = \left(\frac{2}{2\mu^2} \right)^{-\frac{1}{2}} = \mu$$

$$V(\mu) = b''(\theta) = -2 \times \left(-\frac{1}{2} \right) (-2\theta)^{-\frac{3}{2}} = (\mu^{-2})^{-\frac{3}{2}} = \mu^3$$

$$\text{Var}(Y) = \phi b''(\theta) = \frac{\mu^3}{\tau}$$

Algoritmo de estimação para o modelo de regressão logística

- Sem perda de generalidade, vamos considerar $m_i = 1$, para todo $i = 1, 2, \dots, n$, ou seja, a situação de dados não agrupados (distribuição de Bernoulli).
- Neste caso:

$$Y|\mathbf{x} \sim \text{binomial}(1, \mu_{\mathbf{x}})$$

$$\log\left(\frac{\mu}{1-\mu}\right) = \eta_{\mathbf{x}} = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k,$$

uma vez que, neste caso, $\mu_{\mathbf{x}} = \pi_{\mathbf{x}} = P(Y = 1|\mathbf{x})$.

Voltando ao algoritmo de estimação, a variável dependente ajustada, dada por:

$$z_i = \eta_i + (y_i - \mu_i) \frac{\partial \eta_i}{\partial \mu_i}$$

para o caso do modelo de regressão logística fica dado por:

$$z_i = \log\left(\frac{\mu_i}{1-\mu_i}\right) + \frac{y_i - \mu_i}{\mu_i(1-\mu_i)},$$

uma vez que, para o modelo de regressão logística:

$$\eta_i = \log\left(\frac{\mu_i}{1-\mu_i}\right)$$

e

$$\begin{aligned} \frac{\partial \eta_i}{\partial \mu_i} &= \frac{\partial}{\partial \mu_i} \log\left(\frac{\mu_i}{1-\mu_i}\right) = \\ &= \frac{1}{\mu_i(1-\mu_i)}. \end{aligned}$$

- A matriz de pesos, como visto anteriormente, é uma matriz diagonal com elementos:

$$\omega_i = \frac{(\partial \mu_i / \partial \eta_i)^2}{V(\mu_i)}.$$

- No caso do modelo de regressão logística, temos:

$$\omega_i = \mu_i(1-\mu_i),$$

uma vez que:

$$\frac{\partial \mu_i}{\partial \eta_i} = \left(\frac{\partial \eta_i}{\partial \mu_i}\right)^{-1} = \left(\frac{\partial \log\left(\frac{\mu_i}{1-\mu_i}\right)}{\partial \mu_i}\right)^{-1} = \left(\frac{1}{\mu_i(1-\mu_i)}\right)^{-1} = \mu_i(1-\mu_i),$$

e $V(\mu_i) = \mu_i(1 - \mu_i)$. Logo,

$$\omega_i = \frac{(\partial \mu_i / \partial \eta_i)^2}{V(\mu_i)} = \frac{[\mu_i(1 - \mu_i)]^2}{\mu_i(1 - \mu_i)} = \mu_i(1 - \mu_i),$$

de tal forma que o estimador de β via mínimos quadrados ponderados fica dado por:

$$\hat{\beta} = \left(\mathbf{X}' \hat{\mathbf{W}} \mathbf{X} \right)^{-1} \mathbf{X}' \hat{\mathbf{W}} \hat{\mathbf{z}},$$

em que $\hat{\mathbf{W}}$ é a matriz diagonal $n \times n$ com entradas $\hat{\omega}_i = \hat{\mu}_i(1 - \hat{\mu}_i)$, e $\hat{\mathbf{z}}$ é o vetor de tamanho n com entradas $\hat{z}_i = \log \left(\frac{\hat{\mu}_i}{1 - \hat{\mu}_i} \right) + \frac{y_i - \hat{\mu}_i}{\hat{\mu}_i(1 - \hat{\mu}_i)}$, para $i = 1, 2, \dots, n$.

- Devemos relembrar que tanto $\hat{\beta}$ quanto \mathbf{z} e \mathbf{W} dependem das estimativas dos parâmetros, o que justifica a necessidade de um processo iterativo para estimar os β 's. Detalhes adicionais desse processo podem ser vistos nos scripts em R referentes a esta aula.
- Além disso, a matriz de variância estimada dos estimadores dos β 's fica dada por:

$$\widehat{\text{Var}}(\hat{\beta}) = \left(\mathbf{X}' \hat{\mathbf{W}} \mathbf{X} \right)^{-1}.$$

Algoritmo de estimação para o modelo de regressão Poisson com ligação logarítmica

- Vamos considerar:

$$Y|\mathbf{x} \sim \text{Poisson}(\mu_i)$$

$$g(\mu_{\mathbf{x}}) = \log(\mu_{\mathbf{x}}) = \eta_{\mathbf{x}} = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k$$

A variável dependente ajustada, dada por:

$$z_i = \eta_i + (y_i - \mu_i) \frac{\partial \eta_i}{\partial \mu_i}$$

que, para o caso do modelo de regressão Poisson com ligação logarítmica, fica dada por:

$$z_i = \log(\mu_i) + \frac{y_i - \mu_i}{\mu_i}$$

uma vez que, para o modelo de regressão Poisson com ligação logarítmica:

$$\eta_i = \log(\mu_i)$$

e

$$\frac{\partial \eta_i}{\partial \mu_i} = \frac{\partial}{\partial \mu_i} \log(\mu_i) = \frac{1}{\mu_i}.$$

- A matriz de pesos, como visto anteriormente, é uma matriz diagonal com elementos:

$$\omega_i = \frac{(\partial \mu_i / \partial \eta_i)^2}{V(\mu_i)}.$$

- No caso do modelo de regressão gama com ligação inversa, temos:

$$\omega_i = \mu_i,$$

uma vez que:

$$\frac{\partial \mu_i}{\partial \eta_i} = \left(\frac{\partial \eta_i}{\partial \mu_i} \right)^{-1} = \left(\frac{\partial \log(\mu_i)}{\partial \mu_i} \right)^{-1} = \mu_i,$$

e $V(\mu_i) = \mu_i$. Logo,

$$\omega_i = \frac{(\partial \mu_i / \partial \eta_i)^2}{V(\mu_i)} = \frac{\mu_i^2}{\mu_i} = \mu_i,$$

de tal forma que o estimador de β via mínimos quadrados ponderados fica dado por:

$$\hat{\beta} = \left(\mathbf{X}' \hat{\mathbf{W}} \mathbf{X} \right)^{-1} \mathbf{X}' \hat{\mathbf{W}} \hat{\mathbf{z}},$$

em que $\hat{\mathbf{W}}$ é a matriz diagonal $n \times n$ com entradas $\hat{\omega}_i = \hat{\mu}_i$ e $\hat{\mathbf{z}}$ é o vetor de tamanho n com entradas $z_i = \log(\mu_i) + \frac{y_i - \mu_i}{\mu_i}$, para $i = 1, 2, \dots, n$.

- A matriz de variância estimada dos estimadores dos β 's fica dada por:

$$\widehat{\text{Var}}(\hat{\beta}) = \left(\mathbf{X}' \hat{\mathbf{W}} \mathbf{X} \right)^{-1}.$$

Algoritmo de estimação para o modelo de regressão gama com ligação inversa

- Vamos considerar:

$$Y|\mathbf{x} \sim \text{gamma}(\mu_i, \nu)$$

$$g(\mu_{\mathbf{x}}) = \frac{1}{\mu_{\mathbf{x}}} = \eta_{\mathbf{x}} = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k$$

A variável dependente ajustada, dada por:

$$z_i = \eta_i + (y_i - \mu_i) \frac{\partial \eta_i}{\partial \mu_i}$$

para o caso do modelo de regressão gama com ligação inversa fica dada por:

$$z_i = \frac{1}{\mu_i} - \frac{y_i - \mu_i}{\mu_i^2} = \frac{1}{\mu_i} + \frac{\mu_i - y_i}{\mu_i^2}$$

uma vez que, para o modelo de regressão gama com ligação inversa:

$$\eta_i = \frac{1}{\mu_i}$$

e

$$\frac{\partial \eta_i}{\partial \mu_i} = \frac{\partial}{\partial \mu_i} \frac{1}{\mu_i} = -1/\mu_i^2.$$

- A matriz de pesos, como visto anteriormente, é uma matriz diagonal com elementos:

$$\omega_i = \frac{(\partial \mu_i / \partial \eta_i)^2}{V(\mu_i)}.$$

- No caso do modelo de regressão gama com ligação inversa, temos:

$$\omega_i = \mu_i^2,$$

uma vez que:

$$\frac{\partial \mu_i}{\partial \eta_i} = \left(\frac{\partial \eta_i}{\partial \mu_i} \right)^{-1} = \left(\frac{\partial \left(\frac{1}{\mu_i} \right)}{\partial \mu_i} \right)^{-1} = \mu_i^2,$$

e $V(\mu_i) = \mu_i^2$. Logo,

$$\omega_i = \frac{(\partial \mu_i / \partial \eta_i)^2}{V(\mu_i)} = \frac{\mu_i^4}{\mu_i^2} = \mu_i^2,$$

de tal forma que o estimador de β via mínimos quadrados ponderados fica dado por:

$$\hat{\beta} = \left(\mathbf{X}' \hat{\mathbf{W}} \mathbf{X} \right)^{-1} \mathbf{X}' \hat{\mathbf{W}} \hat{\mathbf{z}},$$

em que $\hat{\mathbf{W}}$ é a matriz diagonal $n \times n$ com entradas $\hat{\omega}_i$ e $\hat{\mathbf{z}}$ é o vetor de tamanho n com entradas $\hat{z}_i = \frac{1}{\hat{\mu}_i} + \frac{y_i - \hat{\mu}_i}{\hat{\mu}_i^2}$, para $i = 1, 2, \dots, n$.

- A matriz de variância estimada dos estimadores dos β 's fica dada por:

$$\widehat{\text{Var}}(\hat{\beta}) = \left(\mathbf{X}' \hat{\mathbf{W}} \mathbf{X} \right)^{-1}.$$

Função desvio para as principais distribuições pertencentes à família exponencial

• Distribuição binomial

Para a distribuição binomial, assumimos $Y_i \sim \text{binomial}(\mu_i, \pi_i)$, de tal forma que, como visto anteriormente, $\tilde{\theta}_i = \log \{y_i/(m_i - y_i)\}$ e $\hat{\theta}_i = \log \{\hat{\mu}_i/(m_i - \hat{\mu}_i)\}$; $b(\tilde{\theta}_i) = -\log(1 - y_i)$, $b(\hat{\theta}_i) = -\log(1 - \hat{\mu}_i)$, produzindo:

$$D(\mathbf{y}, \hat{\mu}) = 2 \sum_{i=1}^n \left[y_i \log \left(\frac{y_i}{m_i \hat{\mu}_i} \right) + (m_i - y_i) \log \left(\frac{m_i - y_i}{1 - \hat{\mu}_i} \right) \right]$$

• Distribuição Poisson

Para a distribuição Poisson, assumimos $Y_i \sim \text{Poisson}(\mu_i)$, de tal forma que, como visto anteriormente, $\tilde{\theta}_i = \log(y_i)$ e $\hat{\theta}_i = \log(\hat{\mu}_i)$; $b(\tilde{\theta}_i) = y_i$, $b(\hat{\theta}_i) = \hat{\mu}_i$ produzindo:

$$D(\mathbf{y}, \hat{\mu}) = 2 \sum_{i=1}^n \left[y_i \log \left(\frac{y_i}{\hat{\mu}_i} \right) - (y_i - \hat{\mu}_i) \right]$$

• Distribuição normal

Para a distribuição normal, assumimos $Y_i \sim \text{normal}(\mu_i, \sigma^2)$, de tal forma que, como visto anteriormente, $\tilde{\theta}_i = y_i$ e $\hat{\theta}_i = \hat{\mu}_i$; $b(\tilde{\theta}_i) = y_i^2/2$ e $b(\hat{\theta}_i) = \hat{\mu}_i^2$, produzindo:

$$D(\mathbf{y}, \hat{\mu}) = 2 \sum_{i=1}^n \left[y_i(y_i - \hat{\mu}_i) + \frac{\hat{\mu}_i^2 - y_i^2}{2} \right] = \sum_{i=1}^n (y_i - \hat{\mu}_i)^2 / 2,$$

que é a soma de quadrados dos resíduos.

• Distribuição gama

Para a distribuição gama, assumimos $Y_i \sim \text{gama}(\mu_i, \nu)$, de tal forma que, como visto anteriormente, $\tilde{\theta}_i = -1/y_i$ e $\hat{\theta}_i = -1/\hat{\mu}_i$; $b(\tilde{\theta}_i) = \log(y_i)$ e $b(\hat{\theta}_i) = \log(\hat{\mu}_i)$, produzindo:

$$D(\mathbf{y}, \hat{\mu}) = 2 \sum_{i=1}^n \left[-\log \left(\frac{y_i}{\hat{\mu}_i} \right) + \frac{y_i - \hat{\mu}_i}{\hat{\mu}_i} \right]$$

• Distribuição normal inversa

Para a distribuição normal inversa, assumimos $Y_i \sim \text{normal inversa}(\mu_i, \tau)$, de tal forma que, como visto anteriormente, $\tilde{\theta}_i = -1/2y_i^2$ e $\hat{\theta}_i = -1/2\hat{\mu}_i^2$; $b(\tilde{\theta}_i) = -1/y_i$ e $b(\hat{\theta}_i) = -1/\hat{\mu}_i$, produzindo:

$$D(\mathbf{y}, \hat{\mu}) = 2 \sum_{i=1}^n \frac{(y_i - \hat{\mu}_i)^2}{y_i \hat{\mu}_i^2}.$$