

Universidade Federal do Paraná - Departamento de Estatística
CE071 - Análise de Regressão Linear
Prof. Cesar Augusto Taconeli
Lista de exercícios

1. Defina o modelo de regressão linear simples. Especifique cada um de seus componentes e as suposições assumidas para os erros.

Resposta:

$$y = \beta_0 + \beta_1 x + \epsilon, \quad \epsilon \sim N(0, \sigma^2),$$

com $\text{Cov}(\epsilon_i, \epsilon_j) = 0$ para $i \neq j$.

2. Qual o princípio da estimação por mínimos quadrados? Quais as principais propriedades dos estimadores de mínimos quadrados dos parâmetros de um modelo de regressão linear?

Resposta: Encontrar valores para os parâmetros tais que a soma dos quadrados dos erros seja mínima. Os estimadores de mínimos quadrados são não viciados, lineares (são combinações lineares dos y 's) e, na classe dos estimadores lineares não viciados, são os mais eficientes (Teorema de Gauss Markov).

3. Qual o princípio da estimação por máxima verossimilhança? Qual a relação dos estimadores de mínimos quadrados e de máxima verossimilhança dos parâmetros do modelo de regressão linear se assumirmos que os erros são normalmente distribuídos?

Resposta: Encontrar valores para os parâmetros tais que a função de verossimilhança atinja seu máximo. Se os erros forem normalmente distribuídos, os estimadores de mínimos quadrados e de máxima verossimilhança dos β 's são idênticos.

4. Considere o modelo de regressão linear simples com $\beta_0 = 10$, $\beta_1 = 5$ e $\sigma = 4$. Assuma distribuição normal para os erros.

- a) Apresente gráficos da distribuição de y condicional a (i) $x = 3$; (ii) $x = 5$ e (iii) $x = 10$;
b) Descreva o significado de β_0 e β_1 . Suponha que $x = 0$ pertença ao escopo do modelo;

Resposta: $\beta_0 = 10$ corresponde ao valor esperado (média) de y quando $x = 0$. $\beta_1 = 5$ significa que para cada acréscimo de uma unidade em x espera-se um acréscimo de 5 unidades em y .

- c) Calcule $P(20 < y < 30)$ para: (i) $x = 3$; $x = 5$.

Resposta:

Para $x = 3$, $y \sim N(\mu = 10 + 5 \times 3 = 25, \sigma = 4)$. Então,

$$\begin{aligned} P(20 < y < 30) &= P\left(\frac{20 - 25}{4} < Z < \frac{30 - 25}{4}\right) \\ &= P(-1.25 < Z < 1.25) = 0.7887 \end{aligned}$$

Para $x = 5$, $y \sim N(\mu = 10 + 5 \times 5 = 35, \sigma = 4)$. Então,

$$\begin{aligned} P(20 < y < 30) &= P\left(\frac{20 - 35}{4} < Z < \frac{30 - 35}{4}\right) \\ &= P(-3.75 < Z < -1.25) = 0.1055 \end{aligned}$$

5. Considere o modelo de regressão linear simples com $\beta_0 = 10$; $\beta_1 = 0.5$ e $\sigma = 1$. Assuma que os erros sejam normalmente distribuídos.

a) Simule uma amostra de $n = 10$ observações para y locadas em $x = -2, -1, 0, 1$ e 2 (duas observações para cada valor de x);

Resposta:

```
x <- rep(-2:2, each = 2)
y <- rnorm(10, mean = 10 + 0.5*x, sd = 1)
y
```

```
## [1] 8.354236 8.278256 9.907160 9.449209 10.831377 9.232854 9.876681
## [8] 10.154397 12.464605 10.444337
```

b) Ajuste um modelo de regressão linear simples aos dados simulados no item *a*. Extraia as estimativas de β_0 e β_1 .

Resposta:

```
fit <- lm(y ~ x)
coef(fit)
```

```
## (Intercept)          x
##  9.8993112    0.6613805
```

```
summary(fit)
```

```
##
## Call:
## lm(formula = y ~ x)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.7777 -0.6014 -0.2603  0.5547  1.2425
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   9.8993     0.2430  40.731 1.45e-10 ***
## x             0.6614     0.1719   3.848  0.00489 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.7686 on 8 degrees of freedom
## Multiple R-squared:  0.6493, Adjusted R-squared:  0.6054
## F-statistic: 14.81 on 1 and 8 DF, p-value: 0.004888
```

c) Repita os itens *a* e *c* 5000 vezes. Armazene as estimativas obtidas numa matriz com duas colunas (uma referente a cada parâmetro);

Resposta:

```
mat_estimat <- matrix(0, nrow = 500, ncol = 2)
mat_erros <- matrix(0, nrow = 500, ncol = 2)


for(i in 1:500){
  y <- rnorm(10, mean = 10 + 0.5*x, sd = 1)
  fit_sim <- lm(y ~ x)
  mat_estimat[i,] <- coef(fit_sim)
  mat_erros[i,] <- summary(fit_sim)$coefficients[, 'Std. Error']
}
head(mat_estimat, 10)
```

```
##           [,1]      [,2]
## [1,]  9.319043 0.4086232
## [2,]  9.613736 0.1710792
## [3,]  9.741475 0.6016124
## [4,] 10.093268 0.9928546
## [5,]  9.875936 0.2875544
## [6,] 10.011281 0.6394971
## [7,] 10.029699 0.4350332
## [8,] 10.532902 0.6418812
## [9,] 10.063791 0.1055994
## [10,]  9.974412 0.2490291
```

- d) Construa histogramas e calcule média e variância das estimativas produzidas para cada parâmetro. Compare os resultados obtidos na simulação aos apresentados no item *b*;

Resposta:

```
par(mfrow = c(1,3))
hist(mat_estimat[,1], xlab = expression(beta[0]), main = "")
abline(v = coef(fit)[1], col = 'red', lwd = 2)
hist(mat_estimat[,2], xlab = expression(beta[1]), main = "")
abline(v = coef(fit)[2], col = 'red', lwd = 2)
plot(mat_estimat[,1], mat_estimat[,2], xlab = expression(beta[0]), ylab = expression(beta[1]), col = 'gray',
points(x = coef(fit)[1], y = coef(fit)[2], cex = 2, pch = 20, col = 'red'))
```



e) Para cada uma das 5000 simulações, obtenha os intervalos de confiança 95% para β_0 e β_1 . Qual proporção dos intervalos contém os valores fixados para os respectivos parâmetros?

Resposta:

```
mat_ICs_beta0 <- matrix(0, nrow = 500, ncol = 2)
mat_ICs_beta1 <- matrix(0, nrow = 500, ncol = 2)

for(i in 1:500){
  mat_ICs_beta0[i,] <- c(mat_estimat[i,1] + qt(0.025, df = 10-2) * mat_erros[i,1],
                        mat_estimat[i,1] + qt(0.975, df = 10-2) * mat_erros[i,1])
  mat_ICs_beta1[i,] <- c(mat_estimat[i,2] + qt(0.025, df = 10-2) * mat_erros[i,2],
                        mat_estimat[i,2] + qt(0.975, df = 10-2) * mat_erros[i,2])
}

mean(mat_ICs_beta0[,1] < 10 & mat_ICs_beta0[,2] > 10)

## [1] 0.96

mean(mat_ICs_beta1[,1] < 0.5 & mat_ICs_beta1[,2] > 0.5)

## [1] 0.96
```

6. Considere o modelo de regressão linear simples sem intercepto:

$$y = \beta x + \epsilon,$$

com as suposições usuais para os erros para o modelo de regressão linear.

- Mencione uma situação prática em que o modelo de regressão linear passando pela origem possa ser considerado;
- Determine o estimador de mínimos quadrados de β ;
- Obtenha esperança e variância para o estimador deduzido no item *b*.

7. Neste exercício consideramos transformações lineares de x e y . Em todos os itens, considere o modelo de regressão linear simples conforme especificado em sala de aula. Sejam β_0 , β_1 , SQE e r os parâmetros do modelo, a soma de quadrados dos erros e o coeficiente de correlação, respectivamente.

- Suponha que cada valor de x seja transformado usando $x' = x - 10$ e a regressão linear simples de y em x' . Como ficam β'_0 , β'_1 , SQ'_{Res} e r' ? O que acontece com essas quantidades quando $x' = 10x$? E quando $x' = 10(x - 1) = 10x - 10$?

Resolução:

Seja $x' = x - 10$. Então:

$$\begin{aligned}\hat{\beta}'_1 &= \frac{\sum(x'_i - \bar{x}')(y_i - \bar{y})}{\sum(x'_i - \bar{x}')^2} \\ &= \frac{\sum((x_i - 10) - (\bar{x} - 10))(y_i - \bar{y})}{\sum((x_i - 10) - (\bar{x} - 10))^2} \\ &= \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sum(x_i - \bar{x})^2} \\ &= \hat{\beta}_1\end{aligned}$$

e

$$\begin{aligned}\hat{\beta}'_0 &= \bar{y} - \hat{\beta}'_1 \bar{x}' \\ &= \bar{y} - \hat{\beta}_1 (\bar{x} - 10) \\ &= \bar{y} - \hat{\beta}_1 \bar{x} - 10\hat{\beta}_1 \\ &= \hat{\beta}_0 - 10 \times \hat{\beta}_1\end{aligned}$$

e

$$\begin{aligned}SQ'_{\text{Res}} &= \sum(y_i - (\hat{\beta}'_0 + \hat{\beta}'_1 x'_i))^2 \\ &= \sum(y_i - (\hat{\beta}_0 - 10\hat{\beta}_1 + \hat{\beta}_1(x_i - 10)))^2 \\ &= \sum(y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i))^2 \\ &= SQ_{\text{Res}}\end{aligned}$$

e

$$\begin{aligned}
r' &= \frac{\sum (x'_i - \bar{x}')(y_i - \bar{y})}{\sqrt{\sum (x'_i - \bar{x}')^2} \sqrt{\sum (y_i - \bar{y})^2}} \\
&= \frac{\sum ((x_i - 10) - (\bar{x} - 10))(y_i - \bar{y})}{\sqrt{\sum ((x_i - 10) - (\bar{x} - 10))^2} \sqrt{\sum (y_i - \bar{y})^2}} \\
&= \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}} \\
&= r
\end{aligned}$$

Seja $x' = 10x$. Então:

$$\begin{aligned}
\hat{\beta}'_1 &= \frac{\sum (x'_i - \bar{x}')(y_i - \bar{y})}{\sum (x'_i - \bar{x}')^2} \\
&= \frac{\sum (10x_i - 10\bar{x})(y_i - \bar{y})}{\sum (10x_i - 10\bar{x})^2} \\
&= \frac{10 \sum (x_i - \bar{x})(y_i - \bar{y})}{10^2 \sum (x_i - \bar{x})^2} \\
&= \frac{1}{10} \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} \\
&= \frac{1}{10} \times \hat{\beta}_1
\end{aligned}$$

e

$$\begin{aligned}
\hat{\beta}'_0 &= \bar{y} - \hat{\beta}'_1 \bar{x}' \\
&= \bar{y} - \frac{1}{10} \hat{\beta}_1 10\bar{x} \\
&= \bar{y} - \hat{\beta}_1 \bar{x} \\
&= \hat{\beta}_0
\end{aligned}$$

e

$$\begin{aligned}
SQ'_{\text{Res}} &= \sum (y_i - (\hat{\beta}'_0 + \hat{\beta}'_1 x'_i))^2 \\
&= \sum (y_i - (\hat{\beta}_0 + \frac{1}{10} \hat{\beta}_1 10x_i))^2 \\
&= \sum (y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i))^2 \\
&= SQ_{\text{Res}}
\end{aligned}$$

e

$$\begin{aligned}
r' &= \frac{\sum (x'_i - \bar{x}')(y_i - \bar{y})}{\sqrt{\sum (x'_i - \bar{x}')^2} \sqrt{\sum (y_i - \bar{y})^2}} \\
&= \frac{10 \sum (x_i - \bar{x})(y_i - \bar{y})}{10 \sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}} \\
&= \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}} \\
&= r
\end{aligned}$$

Seja $x' = 10(x - 1)$. Então:

$$\begin{aligned}
\hat{\beta}'_1 &= \frac{\sum (x'_i - \bar{x}')(y_i - \bar{y})}{\sum (x'_i - \bar{x}')^2} \\
&= \frac{\sum (10(x_i - 1) - 10(\bar{x} - 1))(y_i - \bar{y})}{\sum (10(x_i - 1) - 10(\bar{x} - 1))^2} \\
&= \frac{10 \sum (x_i - 1 - \bar{x} + 1)(y_i - \bar{y})}{10^2 \sum (x_i - 1 - \bar{x} + 1)^2} \\
&= \frac{1}{10} \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} \\
&= \frac{1}{10} \times \hat{\beta}_1
\end{aligned}$$

e

$$\begin{aligned}
\hat{\beta}'_0 &= \bar{y} - \hat{\beta}'_1 \bar{x}' \\
&= \bar{y} - \frac{1}{10} \hat{\beta}_1 10(\bar{x} - 1) \\
&= \bar{y} - \hat{\beta}_1 \bar{x} + \hat{\beta}_1 \\
&= \hat{\beta}_0 + \hat{\beta}_1
\end{aligned}$$

e

$$\begin{aligned}
SQ'_{\text{Res}} &= \sum (y_i - (\hat{\beta}'_0 + \hat{\beta}'_1 x'_i))^2 \\
&= \sum (y_i - (\hat{\beta}_0 + \hat{\beta}_1 + \frac{1}{10} \hat{\beta}_1 10(x_i - 1)))^2 \\
&= \sum (y_i - (\hat{\beta}_0 + \hat{\beta}_1 + \hat{\beta}_1 x_i - \hat{\beta}_1))^2 \\
&= \sum (y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i))^2 \\
&= SQ_{\text{Res}}
\end{aligned}$$

e

$$\begin{aligned}
r' &= \frac{\sum (x'_i - \bar{x}')(y_i - \bar{y})}{\sqrt{\sum (x'_i - \bar{x}')^2} \sqrt{\sum (y_i - \bar{y})^2}} \\
&= \frac{\sum (10(x_i - 1) - 10(\bar{x} - 1))(y_i - \bar{y})}{\sqrt{\sum (10(x_i - 1) - 10(\bar{x} - 1))^2} \sqrt{\sum (y_i - \bar{y})^2}} \\
&= \frac{10 \sum (x_i - \bar{x})(y_i - \bar{y})}{10 \sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}} \\
&= \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}} \\
&= r
\end{aligned}$$

- b) Agora, suponha que os valores da variável resposta sejam transformados para $y' = y + 10$ e considere a regressão de y' em x . Como ficam β'_0 , β'_1 , SQ'_{Res} e r' ? O que acontece com essas quantidades quando $y' = 5y$? E quando $y' = 5(y + 2) = 5y + 10$?

Seja $y' = y + 10$. Então:

$$\begin{aligned}
\hat{\beta}'_1 &= \frac{\sum (x_i - \bar{x})(y'_i - \bar{y}')}{\sum (x_i - \bar{x})^2} \\
&= \frac{\sum ((x_i - \bar{x})((y_i + 10) - (\bar{y} + 10)))}{\sum (x_i - \bar{x})^2} \\
&= \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} \\
&= \hat{\beta}_1
\end{aligned}$$

e

$$\begin{aligned}
\hat{\beta}'_0 &= \bar{y}' - \hat{\beta}'_1 \bar{x} \\
&= \bar{y} + 10 - \hat{\beta}_1 \bar{x} \\
&= \bar{y} - \hat{\beta}_1 \bar{x} + 10 \\
&= \hat{\beta}_0 + 10
\end{aligned}$$

e

$$\begin{aligned}
SQ'_{\text{Res}} &= \sum (y'_i - (\hat{\beta}'_0 + \hat{\beta}'_1 x_i))^2 \\
&= \sum (y_i + 10 - (\hat{\beta}_0 + 10 + \hat{\beta}_1 x_i))^2 \\
&= \sum (y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i))^2 \\
&= SQ_{\text{Res}}
\end{aligned}$$

e

$$\begin{aligned}
r' &= \frac{\sum (x_i - \bar{x})(y'_i - \bar{y}')}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y'_i - \bar{y}')^2}} \\
&= \frac{\sum (x_i - \bar{x})(y_i + 10 - (\bar{y} + 10))}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i + 10 - (\bar{y} + 10))^2}} \\
&= \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}} \\
&= r
\end{aligned}$$

Seja $y' = 5y$. Então:

$$\begin{aligned}
\hat{\beta}'_1 &= \frac{\sum (x_i - \bar{x})(y'_i - \bar{y}')}{\sum (x_i - \bar{x})^2} \\
&= 5 \frac{\sum ((x_i - \bar{x})(y_i - \bar{y}))}{\sum (x_i - \bar{x})^2} \\
&= 5 \times \hat{\beta}_1
\end{aligned}$$

e

$$\begin{aligned}
\hat{\beta}'_0 &= \bar{y}' - \hat{\beta}'_1 \bar{x} \\
&= 5\bar{y} - 5\hat{\beta}_1 \bar{x} \\
&= 5(\bar{y} - \hat{\beta}_1 \bar{x}) \\
&= 5 \times \hat{\beta}_0
\end{aligned}$$

e

$$\begin{aligned}
\text{SQ}'_{\text{Res}} &= \sum (y'_i - (\hat{\beta}'_0 + \hat{\beta}'_1 x_i))^2 \\
&= \sum (5y_i - 5(\hat{\beta}_0 + \hat{\beta}_1 x_i))^2 \\
&= 5^2 \sum (y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i))^2 \\
&= 25 \times \text{SQ}_{\text{Res}}
\end{aligned}$$

e

$$\begin{aligned}
r' &= \frac{\sum (x_i - \bar{x})(y'_i - \bar{y}')}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y'_i - \bar{y}')^2}} \\
&= \frac{5 \sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{25} \sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}} \\
&= \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}} \\
&= r
\end{aligned}$$

Seja $y' = 5(y + 2)$. Então:

$$\begin{aligned}
\hat{\beta}'_1 &= \frac{\sum (x_i - \bar{x})(y'_i - \bar{y}')}{\sum (x_i - \bar{x})^2} \\
&= \frac{\sum ((x_i - \bar{x})(5(y_i + 2) - 5(\bar{y} + 2)))}{\sum (x_i - \bar{x})^2} \\
&= \frac{5 \sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} \\
&= 5 \times \hat{\beta}_1
\end{aligned}$$

e

$$\begin{aligned}
\hat{\beta}'_0 &= \bar{y}' - \hat{\beta}'_1 \bar{x} \\
&= 5(\bar{y} + 2) - 5\hat{\beta}_1 \bar{x} \\
&= 5(\bar{y} - \hat{\beta}_1 \bar{x}) + 10 \\
&= 5 \times \hat{\beta}_0 + 10
\end{aligned}$$

e

$$\begin{aligned}
SQ'_{\text{Res}} &= \sum (y'_i - (\hat{\beta}'_0 + \hat{\beta}'_1 x_i))^2 \\
&= \sum (5(y_i + 2) - (5\hat{\beta}_0 + 10 + 5\hat{\beta}_1 x_i))^2 \\
&= 5^2 \sum (y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i))^2 \\
&= 25 \times SQ_{\text{Res}}
\end{aligned}$$

e

$$\begin{aligned}
r' &= \frac{\sum (x_i - \bar{x})(y'_i - \bar{y}')}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y'_i - \bar{y}')^2}} \\
&= \frac{\sum (x_i - \bar{x})(5(y_i + 2) - 5(\bar{y} + 2))}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (5(y_i + 2) - 5(\bar{y} + 2))^2}} \\
&= \frac{5 \sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{25} \sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}} \\
&= r
\end{aligned}$$

c) Em geral, como os resultados da regressão linear simples ficam afetados por transformações lineares em x e em y ?

8. Solicitado a especificar o modelo de regressão linear simples, um aluno escreveu o seguinte:

$$E(y|x) = \beta_0 + \beta_1 x + \epsilon.$$

Você concorda com essa especificação? Justifique.

Resposta:

A especificação está incorreta, uma vez que $E(\epsilon) = 0$.

9. Qual o impacto da ausência de normalidade dos erros nas propriedades dos estimadores de mínimos quadrados do modelo de regressão linear?

Resposta:

Satisfeitas as demais suposições, os estimadores ainda são não viciados e eficientes na classe de estimadores lineares. No entanto, não apresentam distribuição normal.

10. Mostre que:

a) $\sum_{i=1}^n y_i = \sum_{i=1}^n \hat{y}_i$;

$$\begin{aligned}\sum \hat{y}_i &= \sum (\hat{\beta}_0 + \hat{\beta}_1 x_i) \\ &= \sum (\bar{y} - \hat{\beta}_1 \bar{x} + \hat{\beta}_1 x_i) \\ &= n\bar{y} - n\hat{\beta}_1 \bar{x} + n\hat{\beta}_1 \bar{x} \\ &= n\bar{y} = \sum y_i\end{aligned}$$

b) $\sum_{i=1}^n r_i = 0$;

$$\begin{aligned}\sum r_i &= \sum (y_i - \hat{y}_i) \\ &= \sum y_i - \sum \hat{y}_i \\ &= \sum y_i - \sum y_i = 0\end{aligned}$$

c) Para $x = \bar{x}$ tem-se $\hat{y} = \bar{y}$;

$$\begin{aligned}\hat{y} &= \hat{\beta}_0 + \hat{\beta}_1 \bar{x} \\ &= \bar{y} - \hat{\beta}_1 \bar{x} + \hat{\beta}_1 \bar{x} \\ &= \bar{y}\end{aligned}$$

d) $\sum_{i=1}^n (x_i - \bar{x}) = 0$;

$$\sum (x_i - \bar{x}) = \sum x_i - n\bar{x} = n\bar{x} - n\bar{x} = 0$$

e) $\sum_{i=1}^n (x_i - \bar{x})y_i = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$;

$$\begin{aligned}\sum (x_i - \bar{x})(y_i - \bar{y}) &= \sum x_i y_i - \bar{x} \sum y_i - \bar{y} \sum x_i + n\bar{x}\bar{y} \\ &= \sum x_i y_i - \bar{x} \sum y_i - \bar{x} \sum y_i + \bar{x} \sum y_i \\ &= \sum x_i y_i - \bar{x} \sum y_i = \sum (x_i - \bar{x})y_i\end{aligned}$$

f) $\sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2;$

$$\begin{aligned}\sum (x_i - \bar{x})^2 &= \sum x_i^2 - 2\bar{x} \sum x_i + n\bar{x}^2 \\ &= \sum x_i^2 - 2n\bar{x}^2 + n\bar{x}^2 \\ &= \sum x_i^2 - n\bar{x}^2\end{aligned}$$

g) $\sum_{i=1}^n x_i r_i = 0;$

$$\begin{aligned}\sum x_i r_i &= \sum (y_i - \hat{y}_i) x_i \\ &= \sum x_i y_i - \sum x_i \hat{y}_i \\ &= \sum x_i y_i - \sum x_i (\hat{\beta}_0 + \hat{\beta}_1 x_i) \\ &= \sum x_i y_i - \sum x_i (\bar{y} - \hat{\beta}_1 \bar{x}) - \hat{\beta}_1 \sum x_i^2 \\ &= \sum x_i y_i - n\bar{x}\bar{y} + n\hat{\beta}_1 \bar{x}^2 - \hat{\beta}_1 \sum x_i^2 \\ &= \sum x_i y_i - n\bar{x}\bar{y} - \hat{\beta}_1 (\sum x_i^2 - n\bar{x}^2) \\ &= \sum x_i y_i - n\bar{x}\bar{y} - \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} \sum (x_i - \bar{x})^2 \\ &= \sum (x_i - \bar{x})(y_i - \bar{y}) - \sum (x_i - \bar{x})(y_i - \bar{y}) = 0\end{aligned}$$

h) $\sum_{i=1}^n \hat{y}_i r_i = 0.$

$$\begin{aligned}\sum r_i \hat{y}_i &= \sum (y_i - \hat{y}_i) \hat{y}_i \\ &= \sum y_i \hat{y}_i - \sum \hat{y}_i^2 \\ &= \sum y_i (\hat{\beta}_0 + \hat{\beta}_1 x_i) - \sum (\hat{\beta}_0 + \hat{\beta}_1 x_i)^2 \\ &= \hat{\beta}_0 \sum y_i + \hat{\beta}_1 \sum x_i y_i - n\hat{\beta}_0^2 - 2\hat{\beta}_0 \hat{\beta}_1 \sum x_i - \hat{\beta}_1^2 \sum x_i^2 \\ &= (\bar{y} - \hat{\beta}_1 \bar{x}) \sum y_i + \hat{\beta}_1 \sum x_i y_i - n(\bar{y} - \hat{\beta}_1 \bar{x})^2 - 2(\bar{y} - \hat{\beta}_1 \bar{x}) \hat{\beta}_1 n\bar{x} - \hat{\beta}_1^2 \sum x_i^2 \\ &= n\bar{y}^2 - n\hat{\beta}_1 \bar{x}\bar{y} + \hat{\beta}_1 \sum x_i y_i - n\bar{y}^2 + 2n\hat{\beta}_1 \bar{x}\bar{y} - n\hat{\beta}_1^2 \bar{x}^2 - 2n\hat{\beta}_1 \bar{x}\bar{y} + 2n\hat{\beta}_1^2 \bar{x}^2 - \hat{\beta}_1^2 \sum x_i^2 \\ &= \hat{\beta}_1 (\sum x_i y_i - n\bar{x}\bar{y}) - \hat{\beta}_1^2 \sum (x_i - \bar{x})^2 \\ &= \frac{[\sum (y_i - \bar{y})(x_i - \bar{x})]^2}{\sum (x_i - \bar{x})^2} - \frac{[\sum (y_i - \bar{y})(x_i - \bar{x})]^2}{[\sum (x_i - \bar{x})^2]^2} \sum (x_i - \bar{x})^2 = 0\end{aligned}$$

11. Um estudo foi conduzido para avaliar o efeito da temperatura na produção química de um processo. Os seguintes dados foram coletados:

Temp.	-5	-4	-3	-2	-1	0	1	2	3	4	5
Prod.	1	5	4	7	10	8	9	13	14	13	18

Vamos proceder a análise dos dados usando o modelo de regressão linear simples.

- a) Determine as estimativas de mínimos quadrados de β_0 e β_1 e apresente a equação do modelo ajustado.
- b) Apresente um intervalo de confiança (95%) para β_1 ;
- c) Teste a hipótese $H_0 : \beta_1 = 0$ ao nível de significância de 5%;
- d) Apresente os limites de confiança (95%) para a resposta média quando a temperatura é igual a 3;
- e) Apresente limites de confiança (95%) para a diferença nas resposta média quando a temperatura é igual a 3 em relação à resposta média sob temperatura -2;
- f) Sob qual temperatura se estima produção igual a 12?

12. A base de dados **Prestige** do pacote **car** apresenta dados referentes à percepção da população canadense quanto a 102 diferentes profissões. Vamos considerar, para ajuste de um modelo de regressão linear simples, as seguintes variáveis:

- **education**: Educação média dos profissionais (em anos de estudo);
- **prestige**: Escore de prestígio da profissão segundo a resposta dos entrevistados.

Considere o prestígio da profissão como a resposta e a escolaridade média como a variável explicativa.

- a) Ajuste o modelo de regressão linear simples aos dados apresentados e apresente a equação do modelo ajustado;
- b) Construa o diagrama de dispersão e adicione a reta de regressão ajustada. A reta obtida parece se ajustar bem aos dados?
- c) Qual a predição para o escore de prestígio para uma profissão com escolaridade média de 12.5 anos?
- d) Qual o valor ajustado pelo modelo para o prestígio dos administradores públicos (primeira linha da base)? Qual o correspondente resíduo?
- e) Em quanto se estima a variação esperada no escore de prestígio para um ano a mais de escolaridade média entre os profissionais? E para três anos a mais?
- f) O intercepto tem alguma interpretação prática nesta análise?
- g) Apresente uma estimativa para σ^2 ;
- h) Teste a hipótese $H_0 : \beta_1 = 0$ vs $H_1 : \beta_1 \neq 0$ ao nível de significância de 5% e apresente suas conclusões;
- i) Teste a hipótese $H_0 : \beta_1 = 6$ vs $H_1 : \beta_1 \neq 6$ ao nível de significância de 5% e apresente suas conclusões;
- j) Apresente intervalos de confiança (95%) para os parâmetros do modelo;
- k) Apresente intervalos de confiança para a média e de predição considerando (i) $x = 9$; (ii) $x = 15$; (iii) $x = \bar{x}$;
- l) Adicione ao diagrama de dispersão as bandas de confiança e de predição (95%);
- m) Apresente o quadro de análise de variância e o teste F. Compare o p-valor desse teste ao teste da hipótese $H_0 : \beta_1 = 0$;
- n) Calcule o valor de R^2 e interprete-o.

13. Neste exercício vamos analisar os dados de velocidade (x , em milhas por horas) e consumo de combustível (y , em milhas por galão) para $n = 28$ automóveis de certa marca. Os dados estão apresentados no livro *Análise de modelos de regressão linear com aplicações* e disponíveis no pacote **labestData** (base

de dados **CharnetEx3.9**). O objetivo é ajustar um modelo de regressão linear simples para explicar o consumo de combustível em função da velocidade sem usar a função `lm` e suas dependências.

Dados:

$$\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = -1184.39; \quad \sum_{i=1}^n (x_i - \bar{x})^2 = 7316.96; \quad \sum_{i=1}^n (y_i - \hat{y}_i)^2 = 11.20 \quad \bar{x} = 75.54; \quad \bar{y} = 12.89$$

- Usando o R, faça o gráfico de dispersão;
- Calcule as estimativas de mínimos quadrados para β_0 e β_1 . Interprete-as.
- Qual a variação estimada no consumo de combustível para $15mph$ a mais de velocidade?
- Escreva a expressão do modelo ajustado. Calcule o consumo de combustível estimado sob velocidade $x = 75mph$;
- Calcule os erros padrões de $\hat{\beta}_0$ e $\hat{\beta}_1$;
- Estime as variâncias para (i) o consumo médio sob velocidade $x = 75mph$; (ii) o consumo predito para um particular automóvel sob velocidade $x = 75mph$. Compare os resultados;
- Idêntico ao item anterior, mas para velocidade $x = 50mph$. Compare com os resultados do item anterior;
- Apresente intervalos de confiança 95% para β_0 e para β_1 ;
- Apresente intervalos de confiança 95% para o consumo médio e o consumo predito para um novo automóvel sob velocidades: (i) $x = 75mph$; (ii) $x = 50mph$;
- Teste a significância do modelo de regressão, ou seja, teste a hipótese $H_0 : \beta_1 = 0$ vs $H_1 : \beta_1 \neq 0$;
- Um especialista afirma que o consumo de combustível altera, em média, em $-0.18mpg$ para cada unidade a mais de velocidade (em mph). Teste essa hipótese.

Nota: Para as questões envolvendo testes de hipóteses, o seguinte procedimento deve ser aplicado:

- Formulação das hipóteses nula e alternativa;
- Apresentação e cálculo da estatística teste;
- Definição da regra de decisão para os níveis de significância de 5% e 1%;
- Conclusão do problema baseada nas regras de decisão descritas no passo anterior;
- Cálculo do nível descritivo (p -valor) do teste.

14. Sejam y_1 e y_2 variáveis aleatórias com distribuição conjunta normal bivariada, conforme definido na sequência:

$$\begin{pmatrix} y_1 \\ y_2 \end{pmatrix} \sim \text{Normal} \left(\boldsymbol{\mu} = \begin{bmatrix} 6 \\ 2 \end{bmatrix}, \quad \Sigma = \begin{bmatrix} 1 & 0.4 \\ 0.4 & 0.5 \end{bmatrix} \right) \quad (1)$$

- Quais as distribuições marginais de y_1 e y_2 ;
- $y_1 \sim N(6, 1)$ e $y_2 \sim N(2, 0.5)$
- Usando o R, faça gráficos das distribuições (funções densidade de probabilidade) de y_1 , y_2 e da conjunta de y_1 e y_2 ;
 - Qual a distribuição de probabilidades de:
 - $z_1 = y_1 + y_2$
 - $z_2 = \frac{y_1 + y_2}{2}$

$$\text{iii)} \quad z_3 = y_1 - y_2$$

$$\text{iv)} \quad z_4 = 0.875y_1 - 2.278y_2$$

Respostas

$$\text{i)} \quad z_1 \sim N(8, 2.3);$$

$$\text{ii)} \quad z_2 \sim N(4, 0.575);$$

$$\text{iii)} \quad z_3 \sim N(4, 0.7);$$

$$\text{iv)} \quad z_4 \sim N(0.694, 1.765).$$

Nota: Se desejado você pode verificar esses resultados por simulação.

15. Sejam y_1, y_2, \dots, y_{30} variáveis aleatórias independentes com distribuição $y_i \sim N(i, i^2)$, $i = 1, 2, \dots, 30$. Qual a distribuição de $z = y_1 + y_2 + \dots + y_{30}$?

Respostas

$$z \sim N(\sum_{i=1}^{30} i, \sum_{i=1}^{30} i^2)$$

$$\text{Nota: } \sum_{i=1}^{30} i = \frac{30(30+1)}{2} = 465 \text{ e } \sum_{i=1}^{30} i^2 = \frac{30(30+1)(2 \times 30 + 1)}{6} = 9455$$