

**Universidade Federal do Paraná – Departamento de Estatística**  
**Disciplina CEO71 – Análise de Regressão Linear**  
**Prof. Cesar Augusto Taconeli**  
**Lista de exercícios**

**Exercício 1** - Sobre a análise de regressão linear múltipla:

- a) O que a diferencia em relação à regressão linear simples?
- b) Enuncie o modelo de regressão linear múltipla, identificando cada um de seus componentes;
- c) Quais pressuposições são feitas com respeito à distribuição dos erros? Qual a implicação dessas pressuposições em relação à distribuição da variável resposta condicional aos valores das covariáveis?
- d) Qual a interpretação dos parâmetros do modelo de regressão linear múltipla?
- e) Qual o método usado na estimação dos parâmetros? Qual o princípio desse método?
- f) Quais as principais propriedades de  $\hat{\beta}$ , o vetor de estimadores de mínimos quadrados para os parâmetros do modelo?

**Exercício 2** - Considere os seguintes dados:

$$\mathbf{Y} = \begin{bmatrix} 3 \\ 1 \\ 8 \\ 3 \\ 5 \end{bmatrix} ; \quad \mathbf{X}'\mathbf{Y} = \begin{bmatrix} 20 \\ 76 \\ 109 \end{bmatrix} ; \quad (\mathbf{X}'\mathbf{X})^{-1} = \begin{bmatrix} 26,7 & 4,5 & -8,0 \\ 4,5 & 1,0 & -1,5 \\ -8,0 & -1,5 & 2,5 \end{bmatrix}.$$

- a) Apresente o modelo de regressão linear múltipla ajustado;
- b) Interprete as estimativas obtidas para os parâmetros do modelo;
- c) Calcule uma estimativa para a variância do erro aleatório;
- d) Calcule o erro padrão para cada coeficiente do modelo;
- e) Sabendo que a soma dos desvios quadráticos em torno da média é igual a 26.5, calcule e interprete o valor do coeficiente de determinação;
- f) Teste a significância do modelo de regressão ao nível de 1% de significância.

**Exercício 3** - Pretende-se ajustar um modelo de regressão linear múltipla para explicar a variação da viscosidade de um polímero ( $y$ ) em função da temperatura de reação,  $x_1$ , e da taxa de alimentação do catalisador,  $x_2$ . Um experimento realizado com esse objetivo produziu os seguintes resultados:

Polímero	$y$	$x_1$	$x_2$	Polímero	$y$	$x_1$	$x_2$
1	2256	80	8	9	2364	94	12
2	2340	93	9	10	2379	93	11
3	2426	100	10	11	2440	97	13
4	2293	82	12	12	2364	95	11
5	2330	90	11	13	2404	100	8
6	2368	99	8	14	2317	85	12
7	2250	81	8	15	2309	86	9
8	2409	96	10	16	2328	87	12

- Ajuste o modelo de regressão linear múltipla  $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$ . Interprete a estimativa de cada parâmetro;
- Represente graficamente o modelo ajustado;
- Apresente uma estimativa para  $\sigma^2$ ;
- Apresente a matriz de covariâncias estimada de  $\hat{\beta}$ ;
- Estime a viscosidade do polímero para uma temperatura de reação igual a 90 e taxa de alimentação do catalisador igual a 10;
- Calcule o valor ajustado e o resíduo para o polímero de número 5;
- Calcule o valor do coeficiente de determinação do ajuste e comente o resultado obtido.
- Teste a significância do modelo ajustado ao nível de 5%;
- Teste a significância de cada parâmetro do modelo;
- Estime os parâmetros do modelo de regressão por meio de intervalos com 95% de confiança;
- Estime a viscosidade média de polímeros sob temperatura de reação igual a 90 e taxa de alimentação do catalisador igual a 10 por meio de um intervalo com 95% de confiança;
- Preveja a viscosidade de um polímero sob temperatura de reação igual a 90 e taxa de alimentação do catalisador igual a 10 por meio de um intervalo com 95% de confiança;
- Apresente intervalos de confiança simultâneos (95%) para  $\beta_1$  e  $\beta_2$ .

**Nota** – Recomendo que o exercício 3 seja resolvido, num primeiro momento, sem usar a função `lm` e seus recursos. Depois, você poderá usá-la para conferir os resultados.

**Exercício 4** - O arquivo `atletas.csv`, disponível na página da disciplina, contém dados de 200 atletas de determinada modalidade esportiva. As variáveis que compõem a base são as seguintes:

`idade`: Idade da atleta (em anos);  
`imc`: Índice de massa corporal ( $\text{kg}/\text{cm}^2$ );  
`horas`: Horas de treino semanal;  
`massa`: Percentual de massa gorda;  
`gasto`: Gasto semanal com suplementos alimentares (reais);  
`estudo`: Anos de estudo;  
`escore`: Escore de desempenho nas últimas provas (numa escala de 0 a 100).

- Faça uma análise exploratória dos dados. Construa gráficos uni e bivariados, calcule medidas de localização e dispersão para cada variável, obtenha as correlações;
- Ajuste um modelo de regressão linear múltipla tomando o escore de desempenho como a variável resposta. Escreva a expressão do modelo ajustado;
- Qual o valor ajustado pelo modelo para a primeira atleta da base? Qual o resíduo correspondente?

	escore	idade	imc	horas	massa	gasto	estudo
1	79.6	30	20.5	19	21.66	72	15

- Qual a probabilidade estimada de um atleta com características semelhantes à 1ª atleta da base ter escore de desempenho superior a 80? E entre 65 e 75?
- Quais variáveis são estatisticamente significativas ao nível de 5% de significância?
- Qual a variação esperada no escore de desempenho para um aumento de 1% de massa gorda, mantendo fixas as demais variáveis?
- Qual a variação esperada no escore de desempenho para 1 ano a mais de idade, mantendo fixas as demais variáveis?
- Qual a variação esperada no escore de desempenho para 20 reais semanais a mais gastos com suplementos alimentares?
- Obtenha intervalos de confiança (95%) para os parâmetros do modelo;
- Com base nos intervalos de confiança obtidos, você rejeitaria, ao nível de significância de 5%, a hipótese de não efeito da massa muscular no desempenho dos atletas? Justifique sua resposta;
- Ainda com base nos intervalos de confiança, você rejeitaria a hipótese de que o desempenho caia, em média, dois pontos para 1% a mais de massa gorda? Justifique.
- Obtenha a elipse de 95% de confiança para os parâmetros referentes aos efeitos de massa gorda e idade. Adicionalmente, obtenha intervalos de confiança simultâneos, com nível de confiança conjunto igual a 95%. Represente num único gráfico a região de confiança e os intervalos de confiança 95% simultâneos e individuais;
- Obtenha o quadro da análise de variância e conduza o teste da hipótese nula de não significância do modelo de regressão;
- Qual a estimativa para a variância dos erros aleatórios?
- Obtenha o coeficiente de determinação e o coeficiente de determinação ajustado. Interprete-os;
- Ajuste um novo modelo de regressão, desta vez desconsiderando a variável massa gorda. Compare os resultados dos dois ajustes. O que houve com o efeito da variável *imc*? Justifique.
- Voltando ao modelo original, teste a significância conjunta das variáveis *imc* e *estudo*. De acordo com o resultado do teste, poderíamos excluir ambas as variáveis do modelo ao nível de 5% de significância?
- Considere os seguintes perfis de atletas:

Perfil	Idade	IMC	Horas	Massa	Gasto
1	20	20	20	17	100
2	28	23	13	22	60
3	25	21	15	20	85

Para cada um dos perfis apresente um intervalo de confiança (95%) para o escore médio de desempenho e um intervalo de predição (95%) para o escore de um novo atleta com as características apresentadas;

- s) Faça um gráfico de escores observados versus escores ajustados pelo modelo. Acrescente ao gráfico a reta identidade;
- t) Faça um gráfico de resíduos versus escores ajustados. Como os resíduos estão distribuídos?
- u) Padronize cada uma das variáveis explicativas e ajuste um novo modelo de regressão, substituindo as variáveis originais pelas padronizadas. Qual das variáveis apresenta maior efeito no escore de desempenho? Qual a interpretação das estimativas obtidas?