

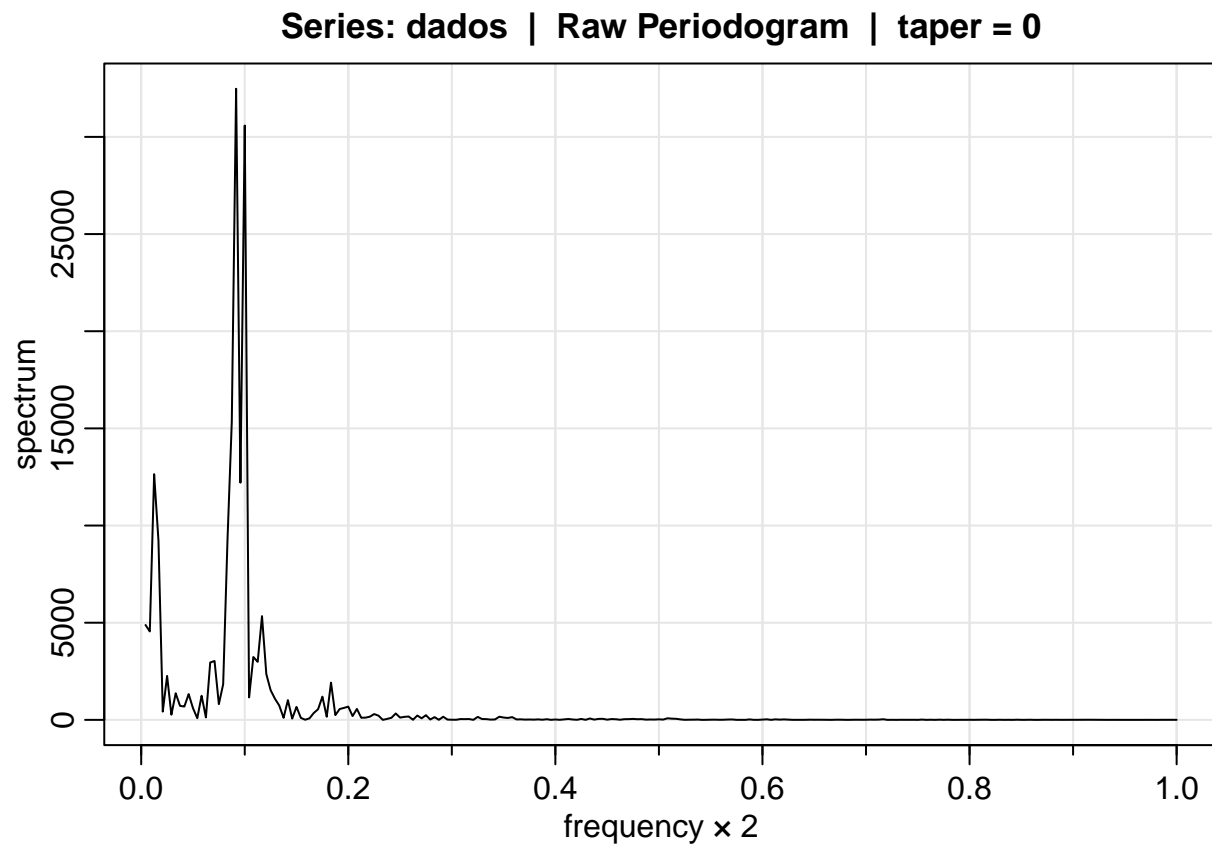
Trabalho 3 relatório

Daniel Krügel

2023-11-06

Questão 9

```
dados <- sunspotz  
A.E <- mvspec(dados, log="no")
```



```
df <- A.E$details # Salvando o vetor de Espectros  
df[which(df[,3] == max(df[,3])),] # plotando qual a frequencia que representa o pico observado no gráfico  
  
## frequency    period  spectrum  
##    0.0917      10.9091 32477.8726
```


Observamos que a frequência que representa o maior espectro no períodograma pe de 0.0917, vamos calcular a quantidade de tempo que leva para fecharmos um ciclo da sazonalidade

```
(freq <- 1/0.0917)
```

```
## [1] 10.90513
```

Representando algo em torno de 11 anos, vamos ver se faz sentido.

```
plot(dados)
```



Plotando a série temporal vemos que a cada 10 anos temos um fechamento de mais ou menos 5 ciclos, o que bate com a informação calculada de frequência.

Intervalo de confiança

Começo retirando quantos graus de liberdade o modelo apresenta:

```
A.E$df #Que ajuda que o pacote dá já salvando essa informação para a gente!
```

```
## [1] 1.9125
```

Vou truncar de 1.9 para 2

```
#Calculando os valores de referencia da chiquadrado  
qchisq(0.025, 2)
```

```
## [1] 0.05063562
```

```
qchisq(0.975, 2)
```

```
## [1] 7.377759
```

Formando o vetor para o intervalo de confiança:

```
c(2*(freq/qchisq(0.975, 2)) , 2*(freq/qchisq(0.025, 2))) #Pouca coisa de amplitude
```

```
## [1] 2.956216 430.729446
```

Com um intervalo tão amplo, fica difícil de dar algum significado ao intervalo de confiança

Questão 20

```
dados <- climhyd
```

```
#Realizando as transformações pedidas no enunciado
```

```
PRECIPTRANS <- sqrt(dados$Precip)
```

```
fit01 <- sarima(PRECIPTRANS, 0,0,0, 0,1,1,12, details = F)
```


```
INFLUXTRANS <- log(dados$Inflow)
```

```
fit02 <- sarima(INFLUXTRANS, 0,0,0, 0,1,1,12, details = F)
```

```
# Construindo os gráficos de Coerencia
```


```
mvspec(cbind(INFLUXTRANS, PRECIPTRANS), plot.type = "coh", spans = c(7,7))
```

series: cbind(INFLUXTRANS, PRECIPTRANS) | Smoothed Periodogram | tai




```
mvspec(cbind(INFLUXTRANS, dados$CldCvr), plot.type = "coh", spans = c(7,7)) #Alguna coherencia
```

series: cbind(INFLUXTRANS, dados\$CldCvr) | Smoothed Periodogram | tap




```
mvspec(cbind(INFLUXTRANS, dados$Temp), plot.type = "coh", spans = c(7,7))
```

Series: cbind(INFLUXTRANS, dados\$Temp) | Smoothed Periodogram | tap




```
mvspec(cbind(INFLUXTRANS, dados$DewPt), plot.type = "coh", spans = c(7,7))
```

series: cbind(INFLUXTRANS, dados\$DewPt) | Smoothed Periodogram | tap



```
mvspec(cbind(INFLUXTRANS, dados$WndSpd), plot.type = "coh", spans = c(7,7))
```

```
series: cbind(INFLUXTRANS, dados$WndSpd) | Smoothed Periodogram | ta
```



Como visto na análise gráfica podemos ver que apenas a Precipitação transformada apresenta uma coerência próxima de 1.0, além disso a cobertura de núvens apresenta uma coesão próxima de 1.0, o que faz sentido dada a alta correlação de precipitação de chuvas e cobertura de núvens

```
#Correlação
```

```
cor(PRECIPTRANS,dados$CldCvr)
```

```
## [1] 0.8256198
```

```
#Teste de correlação
```

```
cor_pmat(cbind(PRECIPTRANS,dados$CldCvr))
```

```
##          PRECIPTRANS
## PRECIPTRANS 0.00000e+00 2.06069e-114
##          2.06069e-114 0.00000e+00
```

Ajustando uma regressão defasada

```
defasada <- LagReg(INFLUXTRANS, PRECIPTRANS)
```

```
## INPUT: INFLUXTRANS OUTPUT: PRECIPTRANS   L = 3 3   M = 40
##
## The coefficients beta(0), beta(1), beta(2) ... beta(M/2-1) are
```

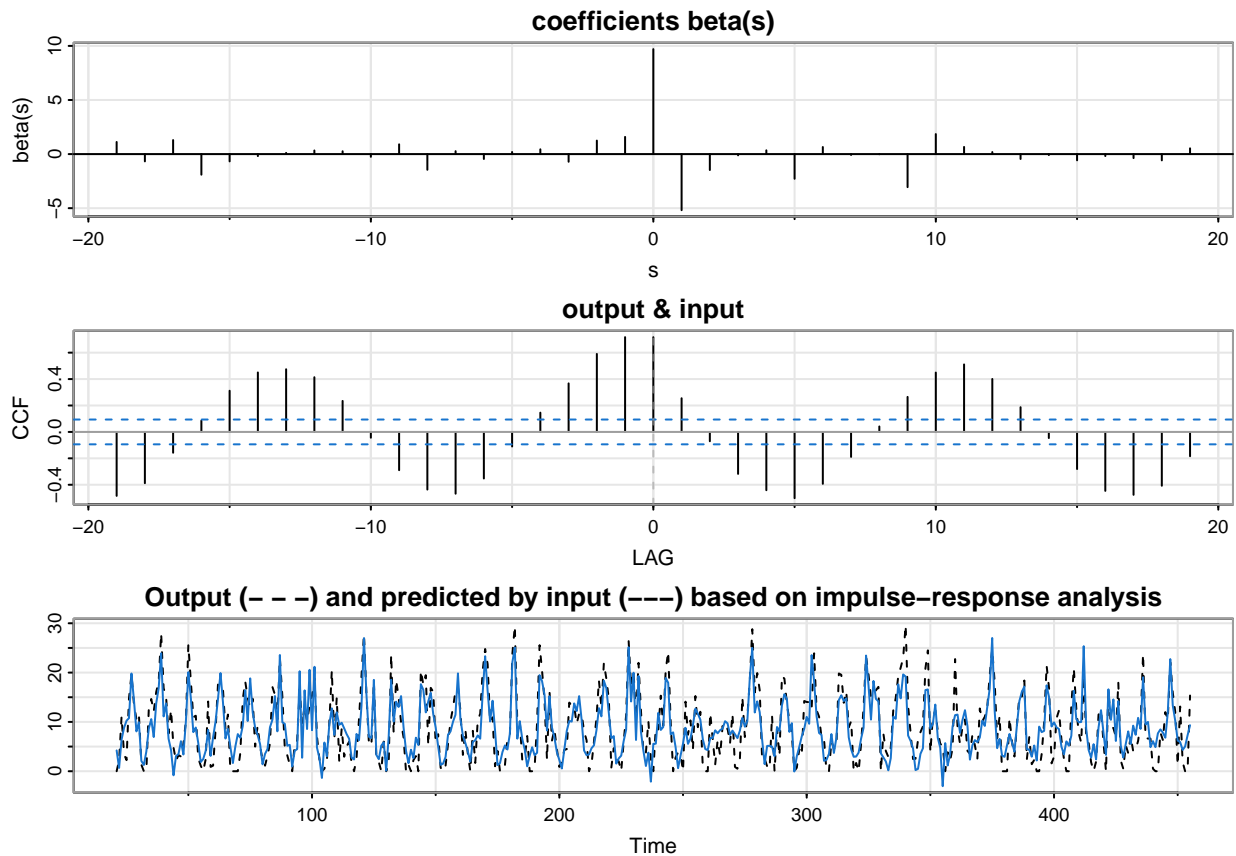


```

##
## 9.70227 -5.186082 -1.473479 -0.115612 0.3496825 -2.285885 0.6552671 -0.08071461
## -0.01690932 -3.057133 1.849937 0.6625569 0.1886431 -0.4532204 -0.09175782
## -0.5780259 -0.1836673 -0.3697189 -0.5825845 0.5357982
##
##
## The coefficients beta(0), beta(-1), beta(-2) ... beta(-M/2+1) are
##
## 9.70227 1.589083 1.249027 -0.7102231 0.4436505 0.1956062 -0.4540404 0.2717492
## -1.4517 0.9054288 -0.2553677 0.262638 0.3343288 0.1121278 -0.1873435 -0.6766232
## -1.906768 1.296012 -0.6756256 1.120138

## The positive lags, at which the coefficients are large
## in absolute value, and the coefficients themselves, are:
##      lag s      beta(s)
## [1,]      0 9.70226985
## [2,]      1 -5.18608206
## [3,]      2 -1.47347910
## [4,]      3 -0.11561205
## [5,]      4 0.34968252
## [6,]      5 -2.28588458
## [7,]      6 0.65526706
## [8,]      7 -0.08071461
## [9,]      8 -0.01690932
## [10,]     9 -3.05713263
## [11,]    10 1.84993658
## [12,]    11 0.66255687
## [13,]    12 0.18864305
## [14,]    13 -0.45322040
## [15,]    14 -0.09175782
## [16,]    15 -0.57802585
## [17,]    16 -0.18366729
## [18,]    17 -0.36971891
## [19,]    18 -0.58258450
## [20,]    19 0.53579820

```




```
##
## The prediction equation is
##  $\text{PRECIPTRANS}(t) = \alpha + \sum_s [\text{beta}(s) * \text{INFLUXTRANS}(t-s)]$ , where  $\alpha = 11.61086$ 
## MSE = 14.25547
```

Como demonstrado no terceiro gráfico, a linha azul “segue” a linha pontilhada, indicando assim que o modelo utilizando a Precipitação Transformada tem um poder preditivo bom para a variável de Influxo transformado

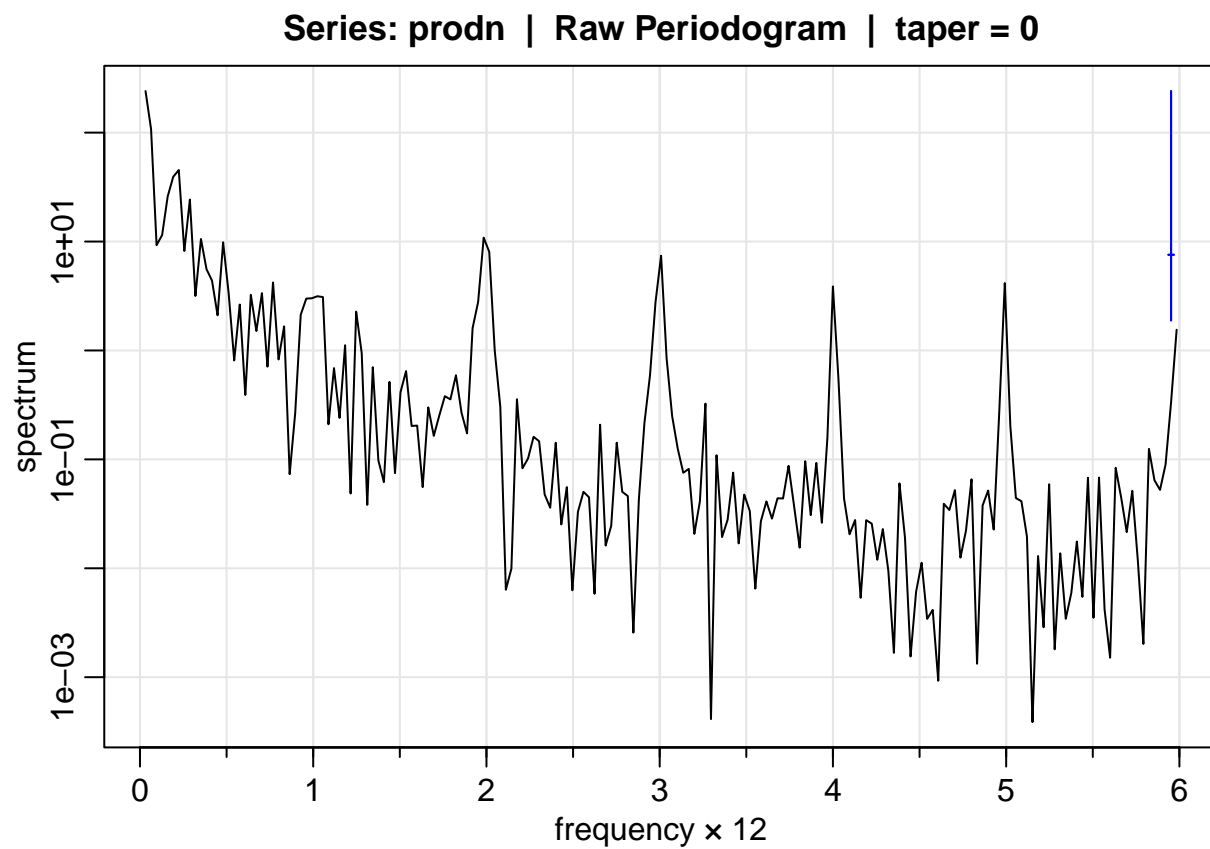
Questão 29

Análise espectrais

```
mvspec(prodn, log = "n")
```

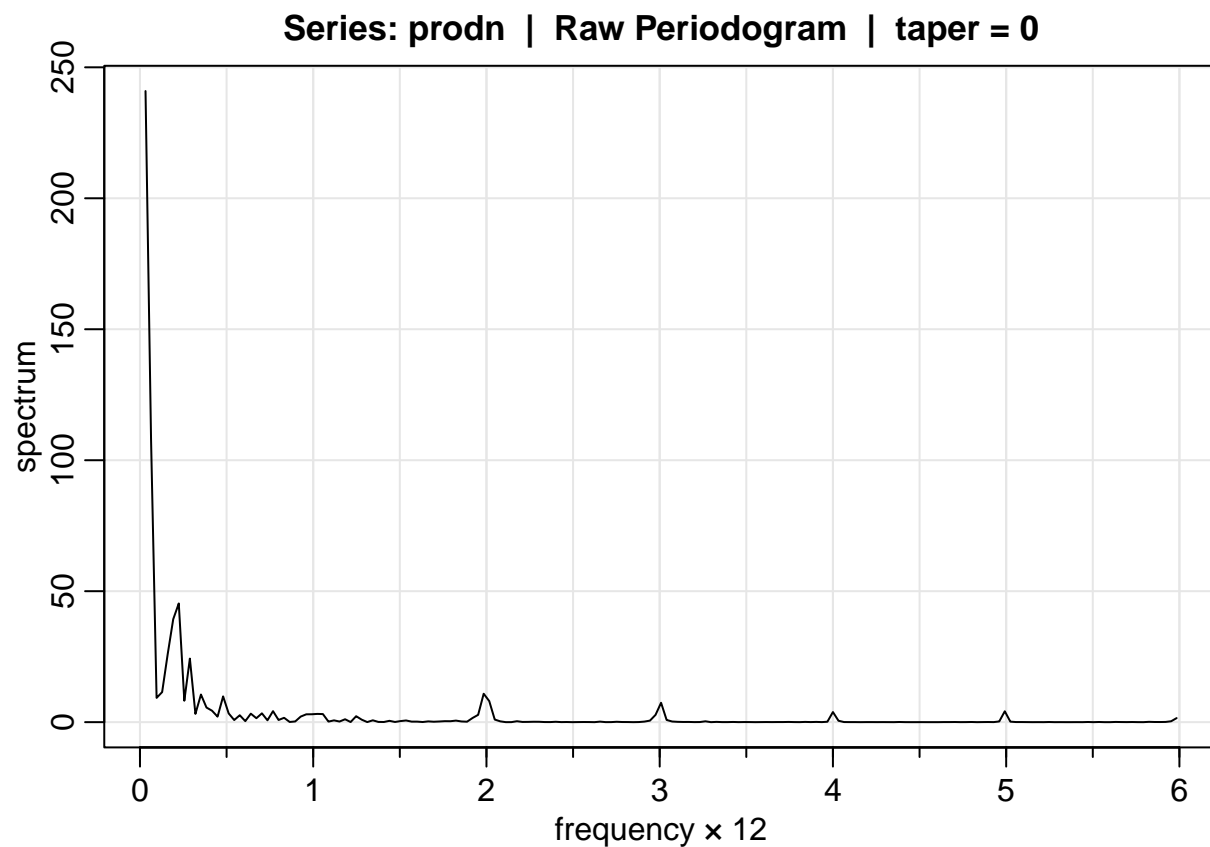


```
mvspec(prodn, log = "y")
```



Para o calculo da frequencia vou seguir os mesmos passos da questão 9

```
# Para produção  
A.E <- mvspec(prodn, log="no")
```



```
df <- A.E$details
```

```
df[which(df[,3] == max(df[,3])),]
```

```
## frequency    period  spectrum
##      0.032     31.250   240.941
```

```
(freq <- 1/0.032)
```

```
## [1] 31.25
```

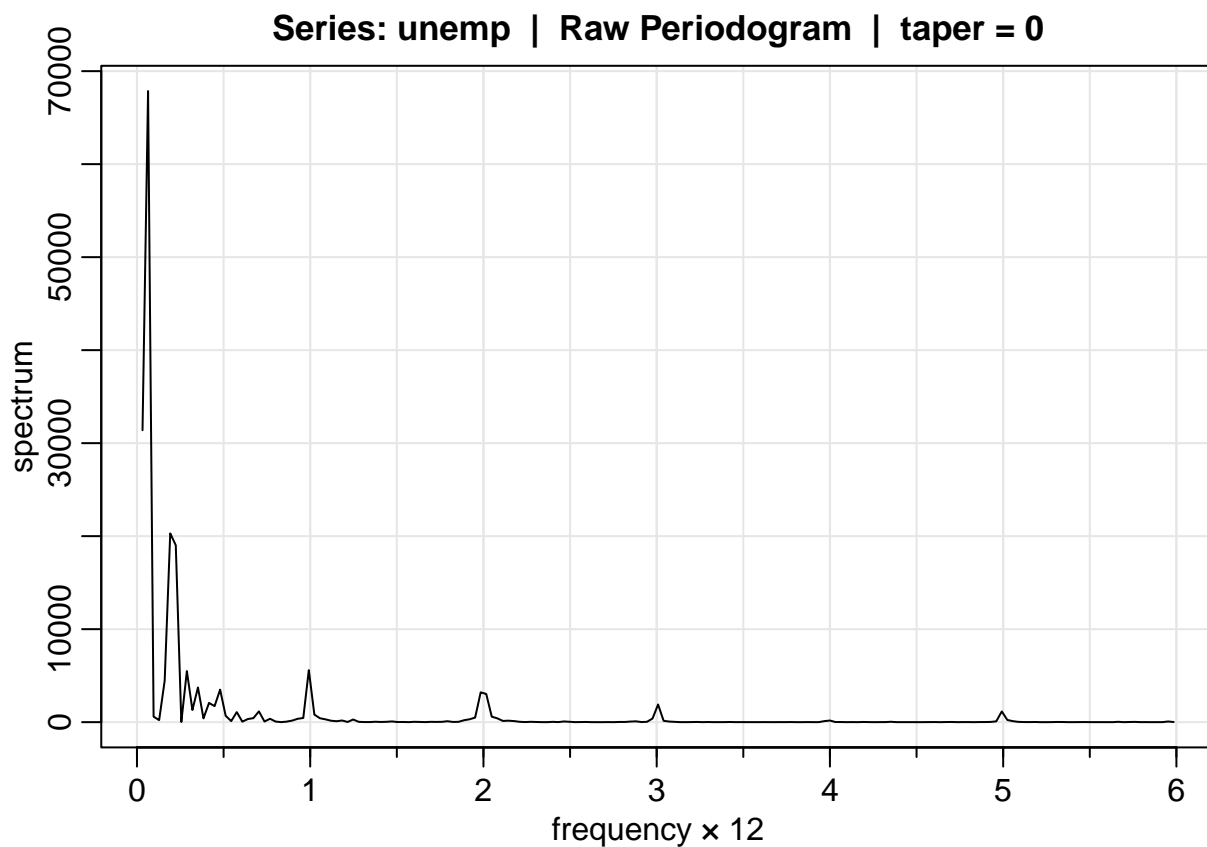
```
#Intervalo de confiança
```

```
c(2*(freq/qchisq(0.975, A.E$df)) , 2*(freq/qchisq(0.025, A.E$df)))
```

```
## [1]      8.510279 1276.364201
```

```
# Para desemprego
```

```
A.E2 <- mvspec(unemp, log="no")
```



```
df2 <- A.E2$details
```

```
df2[which(df2[,3] == max(df2[,3])),]
```

```
## frequency    period  spectrum
##      0.064      15.625 67861.591
```

```
(freq2 <- 1/0.064)
```

```
## [1] 15.625
```

```
#Intervalo de confiança
```

```
c(2*(freq2/qchisq(0.975, A.E2$df)) , 2*(freq2/qchisq(0.025, A.E2$df)))
```

```
## [1] 4.25514 638.18210
```

C)

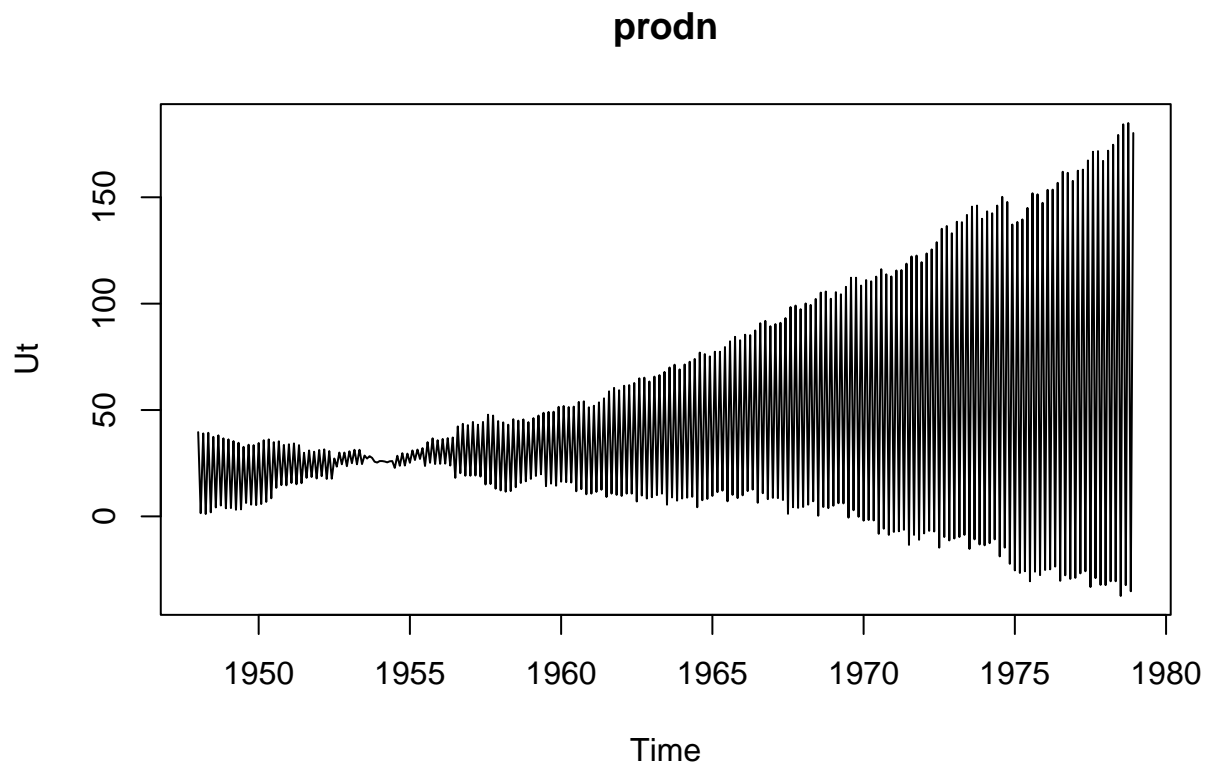
```
dados <- prodn
```

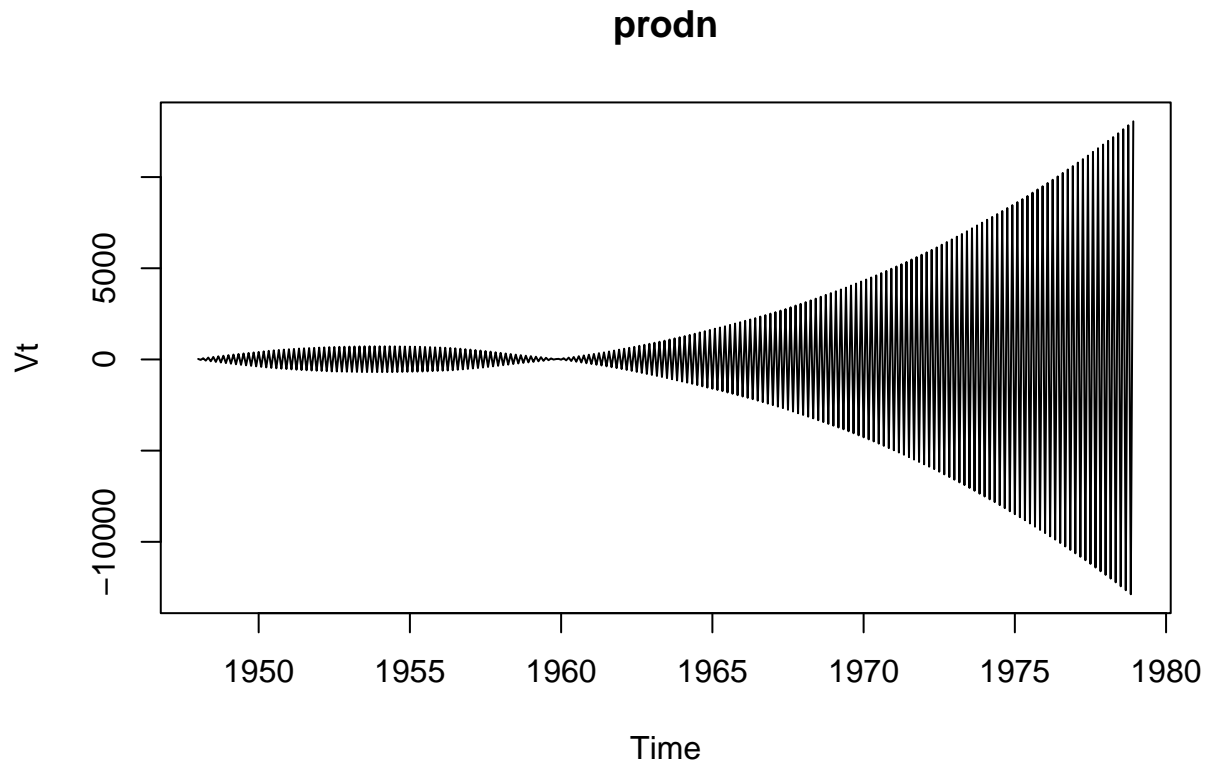
```
Ut <- stats::filter(dados,
                     sides = 1,
                     filter = -1,
                     init = 1,
```

```
method = "recursive")

Vt <- stats::filter(Ut,
  sides = 1,
  filter = -1,
  init = 12,
  method = "recursive")

plot(Ut, main = "prodn"); plot(Vt, main = "prodn")
```



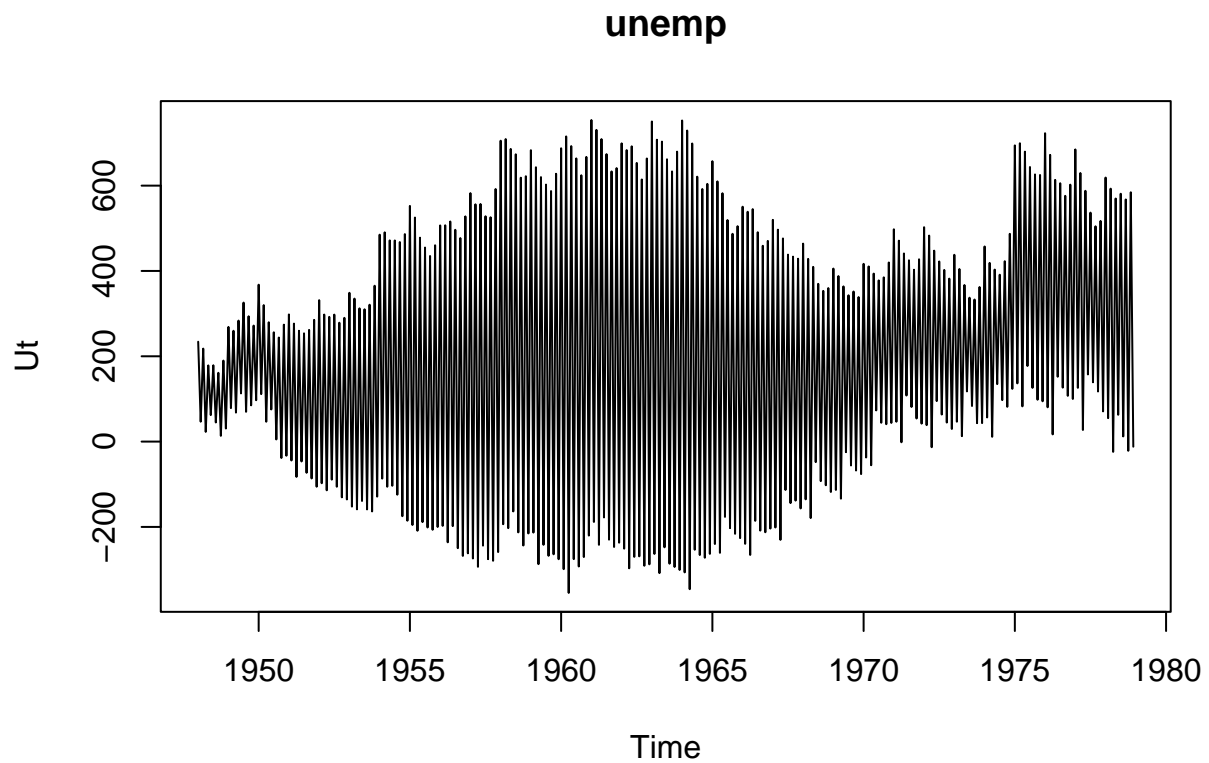


Para produção conseguimos observar o “boom” do pós guerra na produção do país, tanto na nossa série auto regressiva U_t quando V_t

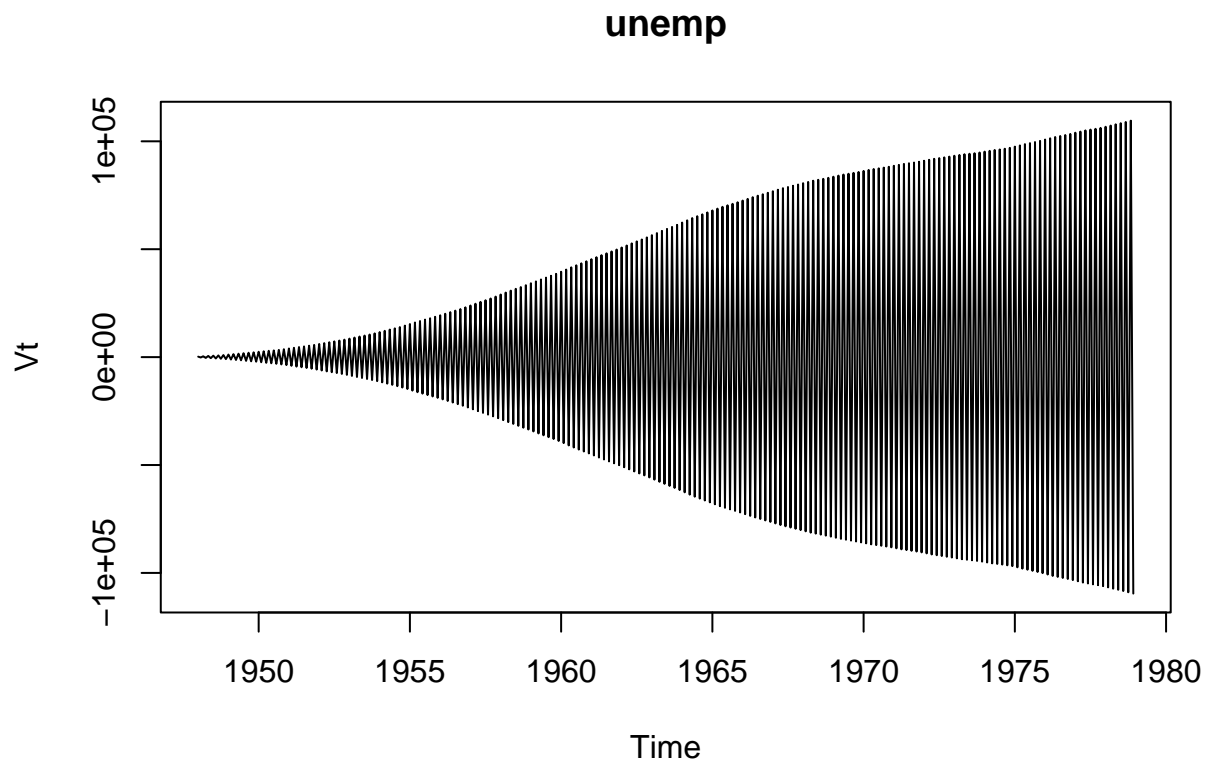
```
dados <- unemp
Ut <- stats::filter(dados,
                    sides = 1,
                    filter = -1,
                    init = 1,
                    method = "recursive")

Vt <- stats::filter(Ut,
                    sides = 1,
                    filter = -1,
                    init = 12,
                    method = "recursive")

plot(Ut, main = "unemp")
```

```
plot(Vt, main = "unemp")
```



Para desemprego vemos dois comportamentos distintos, em U_t percebemos uma diminuição na década de 70 adiante, enquanto em V_t vemos um aumento contínuo apartir da década de 50

Não podemos afirmar que há um padrão de estacionáriedade em nenhuma dessas séries, dada a variância

inconstante da base.